PÓS-GRADUAÇÃO EM DATA SCIENCE E BIG DATA NA INDÚSTRIA

Resumo Teórico e Resolução Completa das Aulas 01 e 02

Fundamentos de Ciência de Dados, Processo KDD, Manipulação com Pandas e Casos Práticos Industriais

Centro Universitário SENAI - Campus Roberto Mange | Prof. Me. Daniel Vieira | 2026

VISÃO GERAL

Estrutura do Estudo e Apresentação

Aula 01: Fundamentos & Metodologia

- Cenário de Data Science e Big Data no setor produtivo
- Fontes de dados na fábrica: sensores IoT, CLPs e telemetria
- O Processo KDD: Seleção, Pré-processamento, Transformação, Mineração e Avaliação
- Primeiros passos com Pandas: Series, DataFrames e manipulação
- Exercício 1: Relação entre temperatura, produção e defeitos em motores
- Exercício 2: Análise de eficiência produtiva e energética de máquinas

Aula 02: Exploração Aplicada & Operações

- Análise Exploratória de Dados (EDA) avançada
- Visualização e mineração com Matplotlib e gráficos de correlação
- Exemplo 2: Desempenho e qualidade de produção por turnos de trabalho
- Exercício 2: Comportamento operacional em logística e transporte
- Exercício 3: Análise comercial histórica, faturamento e elasticidade de preço
- Conexão com as etapas do Projeto Integrador da disciplina

Data Science e Big Data no Ambiente Industrial

Onde a Indústria Gera Dados?

- Sensores de Telemetria: vibração, pressão hidráulica, temperatura, corrente e vazão.
- Automação Fabril: CLPs, sistemas SCADA e redes industriais de chão de fábrica.
- Sistemas de Gestão: ERP (compras/vendas), MES (execução da produção) e CMMS (ordens de manutenção).
- A Pergunta Central do Negócio: 'É possível identificar sinais de falha antes de a máquina parar?'
- A Mudança Cultural: transição do modelo puramente corretivo para a manutenção preditiva orientada a dados.

Papéis & Competências em Data Science

- Cientista de Dados: combina estatística, programação e domínio de processos para modelagem.
- Engenheiro de Dados: constrói os pipelines de ingestão, armazenamento e infraestrutura Big Data.
- Analista de Negócios / Processos: formula perguntas estratégicas e valida o impacto fabril.
- Mineração de Dados (Data Mining): consolidada nos anos 90 como diferencial competitivo para extrair padrões e insights práticos.
- Tecnologias Base: ecossistema Python aberto (Pandas, NumPy, Scikit-Learn e Spark).

O Processo KDD (Knowledge Discovery in Databases)

As 5 Etapas do KDD Aplicadas ao Chão de Fábrica

- 1. Seleção dos Dados: Definição dos sensores e variáveis relevantes para o problema produtivo, descartando telemetrias irrelevantes.
- 2. Pré-processamento: Tratamento de valores nulos (NaN), remoção de leituras inválidas de sensores e eliminação de duplicatas de rede.
- 3. Transformação: Normalização e padronização de escalas discrepantes (ex.: horas em milhares vs vibração unitária), engenharia de novas features (taxas e razões de eficiência).
- 4. Mineração de Dados: Aplicação prática de algoritmos de Machine Learning supervisionados (classificação de falhas) e não supervisionados (clusterização de perfis operacionais).
- 5. Interpretação e Avaliação: Validação das métricas encontradas junto aos especialistas de engenharia e incorporação dos padrões nos painéis e rotinas de manutenção.

Exercício 1: Motores, Temperatura e Defeitos

Estrutura dos Dados & Exploração

- Base analisada: 5 registros de motores industriais (Motor A, Motor B e Motor C).
- Variáveis: produção, peças com defeito e temperatura (°C).
- Produção média geral: 110 peças por lote.
- Temperatura média geral: 75,6 °C (mínima de 68 °C e máxima de 85 °C).
- Agrupamento por Produto:
- • Motor A: produção média = 105 | média defeitos = 5,5
- • Motor B: produção média = 125 | média defeitos = 13,5
- • Motor C: produção média = 90 | média defeitos = 3,0
- Taxa de defeitos criada: Motor B teve a pior taxa (até 11,54%).

Pergunta: Temperatura Causa Defeitos?

- Pergunta Investigativa: 'Será que o aumento de defeitos está relacionado ao aumento da temperatura?'
- Matriz de Correlação de Pearson calculada:
- • Produção x Defeitos: r = +0,9669
- • Produção x Temperatura: r = +0,9693
- • Defeitos x Temperatura: r = +0,9951 (Fortíssima!)
- Conclusão Técnica:
- Existe correlação linear praticamente perfeita (r = 0,995) entre a elevação térmica e a ocorrência de defeitos.
- No chão de fábrica, a temperatura elevada é um indicador direto de sobrecarga ou atrito severo, gerando refugo.

Exercício 2: Análise de Produção e Eficiência Energética

Respostas aos Questionamentos (a a e)

- a) Máquina que produziu mais:
- -> Máquina D com 1.450 peças.
- b) Máquina que menos consumiu energia:
- -> Máquina C com 390 kWh.
- c) Produção média das máquinas:
- -> 1.318,00 peças.
- d) Consumo médio de energia:
- -> 438,00 kWh.
- e) Ordenação decrescente por produção:
- 1º Máquina D (1.450) | 2º Máquina B (1.380) | 3º Máquina E (1.320) | 4º Máquina A (1.250) | 5º Máquina C (1.190).

Cálculo de Eficiência & Insight Industrial (f e g)

- f) Nova coluna: Eficiência = produção / energia (kWh)
- Resultados calculados por equipamento:
- • Máquina A: 1250 / 420 = 2,976 peças/kWh
- • Máquina B: 1380 / 465 = 2,968 peças/kWh
- • Máquina C: 1190 / 390 = 3,051 peças/kWh
- • Máquina D: 1450 / 510 = 2,843 peças/kWh (Pior eficiência!)
- • Máquina E: 1320 / 405 = 3,259 peças/kWh (Campeã!)
- g) Máquina mais eficiente: Máquina E.
- Insight Estratégico: Produzir mais não significa ser mais rentável. A Máquina D teve o maior volume bruto, mas consumiu energia desproporcional.

Análise Exploratória (EDA) e Visualização de Dados

Pilares da Exploração na Prática

- Compreensão de Tipos: variáveis numéricas contínuas (temperatura, horas) vs discretas (peças) vs categóricas (turnos, IDs).
- Investigação de Qualidade: verificação mandatória de duplicatas (.duplicated().sum()) e dados ausentes (.isna().sum()).
- Estatísticas Descritivas Robustas: uso de .describe() para comparar média, desvio-padrão e quartis (Q1, mediana, Q3).
- Tratamento de Strings e Datas: manipulação de timestamps com pd.to_datetime() e conversão de períodos para agrupamentos mensais.
- Agrupamentos Multidimensionais: uso combinado de .groupby() com .agg() aplicando funções distintas por atributo.

Visualização com Matplotlib e Seaborn

- Arquitetura Orientada a Objetos: controle preciso com fig, ax = plt.subplots(figsize=(8,5)).
- Heatmaps de Correlação (Seaborn): indispensáveis para rápida identificação visual de colinearidade e correlação entre sensores.
- Gráficos de Barras e Histogramas: avaliação visual de dispersão de defeitos por turno e distribuição de produção.
- Preparação para Machine Learning: a EDA da Aula 02 é o alicerce para identificar vazamento de dados (data leakage) e selecionar preditores relevantes.

Exemplo 2: Desempenho e Qualidade de Produção por Turno

Volume de Peças e Desempenho por Turno

- Base analisada: producao_por_turno.csv (100 registros com Manhã, Tarde e Noite).
- a) Quantidade total de peças produzidas:
- -> 29.479 peças no período analisado.
- b) Turno com maior produção total:
- -> Turno Manhã lidera com 10.777 peças (Tarde: 9.937 | Noite: 8.765).
- c) Quantidade média de peças por registro:
- • Manhã: 316,97 peças/registro
- • Tarde: 301,12 peças/registro
- • Noite: 265,61 peças/registro

Qualidade da Produção & Correlação

- d) Turno com maior percentual de peças defeituosas:
- • Manhã: 358 defeitos / 10.777 = 3,32% (Maior refugo relativo)
- • Noite: 277 defeitos / 8.765 = 3,16%
- • Tarde: 306 defeitos / 9.937 = 3,08% (Melhor qualidade)
- e) Correlação entre peças produzidas e defeituosas:
- -> Coeficiente de Pearson r = +0,3697
- Interpretação Gerencial:
- Existe correlação positiva moderada (0,37). Turnos mais acelerados (Manhã) geram maior volume bruto, mas demandam reforço no controle de qualidade para conter a taxa de defeitos.

Exercício 2: Operações de Transporte e Logística

Métricas Operacionais da Frota (a a c)

- Base analisada: dados_viagens.csv (100 registros diários de viagens e quilometragem).
- a) Quantidade total de viagens realizadas:
- -> 2.893 viagens completadas no período.
- b) Dia com a maior quantidade de viagens:
- -> 26/02/2026 (Quinta-feira) com 48 viagens.
- c) Média diária de viagens da frota:
- -> 28,93 viagens por dia (desvio-padrão de 9,11).

Sazonalidade Mensal & Correlação (d e e)

- d) Mês com maior quantidade total de viagens:
- • Janeiro/2026: 901 viagens (Maior volume!)
- • Março/2026: 895 viagens
- • Fevereiro/2026: 816 viagens
- • Abril/2026: 281 viagens (dados parciais)
- e) Correlação entre viagens e distância total percorrida:
- -> Coeficiente de Pearson r = +0,8694 (Fortíssima!)
- Conclusão Logística: A distância cresce de forma quase perfeitamente linear com o número de viagens, permitindo prever custos de combustível e pneus com alta precisão.

Exercício 3: Desempenho Comercial do Produto A

Volume de Vendas e Faturamento (a a c)

- Base analisada: dados_vendas.csv (100 meses históricos do Produto A).
- a) Quantidade total de unidades vendidas:
- -> 24.499 unidades vendidas em todo o histórico.
- b) Mês que apresentou o maior faturamento:
- -> Novembro de 2025 (2025-11), com R$ 22.516,32 (366 unidades vendidas a R$ 61,52).
- c) Faturamento total obtido com o Produto A:
- -> R$ 1.281.779,17 acumulados no período.

Evolução Anual & Relação Preço x Vendas (d e e)

- d) Ano com maior quantidade de unidades vendidas:
- -> Ano de 2025 com 3.511 unidades vendidas (evolução constante desde 2018 com 2.330 un).
- e) Relação entre preço unitário e unidades vendidas:
- -> Coeficiente de Pearson r = +0,7713 (Correlação positiva forte)
- Análise Econômica para o Professor:
- Diferente da microeconomia clássica básica (onde preço maior reduz demanda), este caso industrial mostra um produto maduro em expansão contínua de mercado: as vendas cresceram historicamente junto com o reajuste inflacionário do produto.

SÍNTESE DOS APRENDIZADOS

Conexão Metodológica: Das Aulas ao Projeto Final

Evolução Prática do Aluno

- Aula 01: Domínio da sintaxe essencial do Pandas, filtragem condicional, agrupamento e correlação.
- Aula 02: Exploração de cenários operacionais reais (turnos de fábrica, logística de frotas e séries comerciais).
- Maturação Metodológica: aprender a questionar os dados (ex.: por que volume alto não é sinônimo de eficiência; por que correlação não é causalidade).
- Transição para o Projeto Integrador: o pipeline de EDA das Aulas 01 e 02 foi a base exata para tratar os 5.050 registros das máquinas M01-M05.

Impacto no Chão de Fábrica

- Cultura Baseada em Fatos: eliminação do 'achismo' nas ordens de manutenção e de produção.
- Identificação Antecipada de Gargalos: detecção de superaquecimento (como no Exercício 1) antes do travamento mecânico.
- Otimização Energética: priorização de máquinas eficientes (Máquina E vs Máquina D) para redução de custos com eletricidade.
- Próximos Passos: aplicação de modelos supervisionados (Random Forest), clusterização (K-Means) e processamento em cluster com PySpark.

MUITO OBRIGADO PELA ATENÇÃO!

Material de estudo e exercícios das Aulas 01 e 02 concluídos com sucesso.

Disciplina: Data Science e Big Data | Prof. Me. Daniel Vieira | SENAI Roberto Mange