RELATÓRIO ACADÊMICO: RESUMO E EXERCÍCIOS RESOLVIDOS

Aulas 01 e 02: Fundamentos de Ciência de Dados, Processo KDD e Manipulação com Pandas

Instituição: Centro Universitário SENAI Roberto Mange

Disciplina: Data Science e Big Data

Curso: Pós-Graduação em Data Science e Big Data na Indústria

Professor: Me. Daniel Vieira

PARTE 1 — AULA 01: RESUMO TEÓRICO & METODOLÓGICO

1.1 Contexto e Desafio da Indústria 4.0

A indústria moderna enfrenta pressões severas por redução de custos operacionais e confiabilidade de processos. Tradicionalmente, a rotina de manutenção atua de forma **corretiva** (aguarda o travamento do maquinário para atuar), o que desencadeia paradas de linha dispendiosas e multas contratuais. A Ciência de Dados e o Big Data capacitam o setor fabril a responder à pergunta norteadora: *'É possível identificar sinais de falha antes de a máquina parar?'*. A resposta é afirmativa através do monitoramento analítico de variáveis físicas de processo.

1.2 Fontes de Dados no Chão de Fábrica

- **Níveis 0 e 1 (Instrumentação):** Sensores contínuos de temperatura (°C), vibração mecânica (mm/s), pressão hidráulica (bar), corrente (A), vazão e horímetro.
- **Níveis 2 e 3 (Controle e Supervisão):** Controladores Lógicos Programáveis (CLPs), sistemas SCADA e sistemas MES (Manufacturing Execution Systems).
- **Nível 4 (Gestão Corporativa):** Sistemas ERP (faturamento, estoques) e CMMS/GMAO (histórico de ordens de serviço de manutenção).

1.3 O Processo KDD (Knowledge Discovery in Databases)

O KDD é o referencial metodológico padrão para extrair conhecimento valioso a partir de dados brutos industriais, estruturado em cinco fases indispensáveis:

Etapa KDD	Objetivo no Ambiente Industrial	Ação Prática no Pipeline
1. Seleção	Identificar variáveis e sensores relevantes ao problema.	Isolar atributos térmicos, vibratórios e horímetro.
2. Pré-processamento	Higienizar a base contra ruídos e falhas de comunicação.	Tratar nulos (NaN) e expurgar duplicatas de rede.
3. Transformação	Uniformizar grandezas e criar métricas de negócio.	Padronizar escalas e calcular taxas de defeito/consumo.
4. Mineração	Descobrir padrões matemáticos nas leituras operacionais.	Aplicar modelos supervisionados e clusterização.
5. Avaliação	Interpretar métricas e validar com a equipe de chão de fábrica.	Gerar regras no supervisório e semáforos de manutenção.

PARTE 2 — AULA 01: EXERCÍCIOS RESOLVIDOS

Exercício 1: Produção de Motores, Temperatura e Defeitos

Pergunta investigativa: 'Será que o aumento de defeitos está relacionado ao aumento da temperatura?'

Lote / Registro	Produto	Produção	Defeitos	Temperatura (°C)	Taxa Defeito (%)
0	Motor A	100	5	70	5,00%
1	Motor B	120	12	82	10,00%
2	Motor A	110	6	73	5,45%
3	Motor C	90	3	68	3,33%
4	Motor B	130	15	85	11,54%

Resultados e Análise Matemática:
• **Médias Gerais:** Produção média = **110,0 peças** | Temperatura média = **75,6 °C** (mínima de 68 °C e máxima de 85 °C).
• **Agrupamento por Produto:** Motor B apresentou a maior produção (125 peças) e a maior média de defeitos (13,5), enquanto o Motor C teve menor volume (90) e menor refugo (3,0).
• **Matriz de Correlação de Pearson:** Produção x Defeitos: **+0,9669** | Produção x Temperatura: **+0,9693** | **Defeitos x Temperatura: +0,9951**.
Conclusão: Sim, a correlação linear é praticamente perfeita (**r = 0,9951**). O aumento térmico atua como manifestação física de sobrecarga ou desajuste mecânico durante o ciclo, elevando drasticamente a taxa de peças defeituosas.

Exercício 2 (Aula 01 / Exercício 1 da Aula 02): Produção e Eficiência Energética

Máquina	Produção (peças)	Energia (kWh)	Eficiência (peças/kWh)	Classificação
A	1.250	420	2,9762	4ª colocada
B	1.380	465	2,9677	3ª colocada
C	1.190	390	3,0513	Menor consumo / 2ª em eficiência
D	1.450	510	2,8431	Maior produção / Pior eficiência!
E	1.320	405	3,2593	Campeã de Eficiência! ■

Gabarito Oficial das Perguntas:
• **a) Máquina que produziu mais:** Máquina D com **1.450 peças**.
• **b) Máquina com menor consumo de energia:** Máquina C com **390 kWh**.
• **c) Produção média das máquinas: 1.318,00 peças**.
• **d) Consumo médio de energia: 438,00 kWh**.
• **e) Ordem decrescente de produção:** Máquina D (1.450) > B (1.380) > E (1.320) > A (1.250) > C (1.190).
• **f) Eficiência:** Calculada por *produção / energia* (conforme tabela acima).
• **g) Máquina mais eficiente: Máquina E (3,2593 peças/kWh)**.
Lição para Engenharia: O maior volume bruto não reflete o melhor desempenho. A Máquina D produziu mais

peças, porém com a pior eficiência de conversão elétrica da fábrica.

PARTE 3 — AULA 02: RESUMO TEÓRICO & METODOLÓGICO

3.1 Análise Exploratória de Dados (EDA) Avançada

A Aula 02 elevou o rigor analítico ao trabalhar com bases industriais completas contendo 100 registros reais. Uma exploração madura no chão de fábrica investiga três pontos fundamentais:
1. **Classificação dos Atributos:** Variáveis numéricas contínuas (distâncias, horímetro), discretas (peças, viagens) e categóricas (turnos, identificadores).
2. **Integridade da Base:** Contagem sistemática de nulos com .isna().sum() e identificação de repetições espúrias com .duplicated().sum().
3. **Métricas Paramétricas vs Não-Paramétricas:** Confronto entre média e mediana via .describe() para detectar assimetrias operacionais.

3.2 Visualização Orientada a Objetos com Matplotlib e Seaborn

Para gráficos executivos, utiliza-se a estrutura fig, ax = plt.subplots(figsize=(8,5)), onde fig controla a tela geral e ax define o plano cartesiano. O uso de *Heatmaps* (mapas de calor) via Seaborn permite sintetizar a matriz de correlação em cores intuitivas, detectando colinearidades entre sensores em segundos.

PARTE 4 — AULA 02: EXERCÍCIOS RESOLVIDOS

Exemplo 2 (Aula 02): Desempenho e Qualidade de Produção por Turno

Base: producao_por_turno.csv (100 registros de produção nos turnos Manhã, Tarde e Noite)

Turno	Produção Total	Média / Registro	Defeitos Totais	% Defeitos (Refugo)
Manhã	10.777 peças	316,97 peças	358 peças	**3,32%** (Maior taxa!)
Tarde	9.937 peças	301,12 peças	306 peças	**3,08%** (Melhor qualidade)
Noite	8.765 peças	265,61 peças	277 peças	3,16%
Total Geral	**29.479 peças**	**294,79 peças**	**941 peças**	**3,19%**

Gabarito das Perguntas:
• **a) Total produzido no período: 29.479 peças**.
• **b) Turno com maior produção total: Turno Manhã** (10.777 peças).
• **c) Média por registro em cada turno:** Manhã (316,97) | Tarde (301,12) | Noite (265,61).
• **d) Turno com maior percentual de defeitos: Turno Manhã com 3,32%**.
• **e) Correlação Produção x Defeitos: r = +0,3697** (correlação positiva moderada). Lotes com aceleração de volume geram leve aumento na contagem de refugos.

Exercício 2 (Aula 02): Transporte e Logística de Frotas

Base: dados_viagens.csv (100 registros diários de viagens e quilometragem percorrida)

• **a) Total de viagens no período: 2.893 viagens**.
• **b) Dia com maior quantidade de viagens: 26/02/2026 (Quinta-feira)** com pico de **48 viagens** (1.065,5 km percorridos).
• **c) Média diária de viagens: 28,93 viagens/dia** (desvio-padrão de 9,11).
• **d) Mês com maior quantidade de viagens: Janeiro de 2026 (2026-01)** com **901 viagens** (Março teve 895,

Fevereiro teve 816 e Abril teve 281 parciais).
• **e) Correlação Viagens x Distância Total: r = +0,8694** (fortíssima associação linear). O planejamento de rotas é consistente e a quilometragem responde proporcionalmente à demanda de viagens.

Exercício 3 (Aula 02): Desempenho Comercial do Produto A

Base: dados_vendas.csv (100 meses históricos de vendas, preço e receita do Produto A)

• **a) Total de unidades vendidas: 24.499 unidades** ao longo do histórico.
• **b) Mês com maior faturamento: Novembro de 2025 (2025-11)** com receita recorde de **R$ 22.516,32** (366 unidades a R$ 61,52).
• **c) Faturamento total acumulado: R$ 1.281.779,17** gerados pelo Produto A.
• **d) Ano com maior quantidade de unidades vendidas: Ano de 2025 com 3.511 unidades** (crescimento contínuo desde 2018 com 2.330 un).
• **e) Relação Preço Unitário x Vendas: r = +0,7713** (correlação positiva forte).
Interpretação Econômica: Diferente do modelo clássico simples onde aumento de preço retrai demanda, trata-se de um produto industrial em expansão contínua de mercado: as vendas cresceram consistentemente mesmo com os reajustes inflacionários ao longo dos anos.

PARTE 5 — SÍNTESE E INTEGRAÇÃO COM O PROJETO FINAL

O aprendizado das Aulas 01 e 02 consolida os alicerces práticos da formação em Ciência de Dados Industrial. A higienização de telemetria, detecção de outliers e análise de correlações com Pandas serviram de base direta para o desenvolvimento do **Projeto Integrador de Manutenção Preditiva na S&M; Industry**, permitindo fundamentar a divisão temporal de dados (sem data leakage), o modelo supervisionado (Random Forest), o Semáforo de Saúde (K-Means) e a escalabilidade distribuída em cluster com o **Apache Spark (PySpark)**.