ANÁLISE EXPERIMENTAL COM CILINDROS DE PLA COM INTEGRAÇÃO DE INTELIGÊNCIA ARTIFICIAL | EXPERIMENTAL ANALYSIS WITH PLA CYLINDERS INCORPORATING ARTIFICIAL INTELLIGENCE

Silva, E,M
Senai Roberto Mange
edumirgenesis@gmail.com

RESUMO

Identificar peças defeituosas em grandes volumes de produção é um desafio real enfrentado em linhas de produção atuais. Este projeto aposta em uma metodologia integrando conceitos de estatística e inteligência artificial. Os dados experimentais foram coletados para serem submetidos a uma análise baseada no processo **KDD (Knowledge Discovery in Databases)**, que envolve etapas estruturadas de seleção, pré-processamento, transformação, mineração de dados e interpretação de resultados.A partir desse processo, os dados foram tratados e analisados utilizando bibliotecas científicas da linguagem Python, permitindo a realização de análises estatísticas, construção de visualizações gráficas e aplicação de algoritmos de aprendizado de máquina. Em especial, foi empregado o algoritmo **Isolation Forest**, amplamente utilizado para detecção de anomalias em conjuntos de dados experimentais, permitindo identificar padrões atípicos associados a possíveis defeitos internos nas amostras analisadas.Os resultados obtidos evidenciam que a metodologia proposta foi capaz de identificar relações entre variáveis físicas das amostras e seu comportamento mecânico, além de detectar automaticamente exemplares com comportamento anômalo.Adicionalmente, foi conduzida uma análise de estabilidade via reamostragem bootstrap para avaliar a robustez das amostras classificadas como outliers frente a variações no subconjunto de treinamento do modelo, fornecendo uma medida objetiva de confiança na ausência de um gabarito experimental de defeitos Como resultado final do processo analítico, foi gerada uma listagem estruturada em formato CSV contendo os identificadores das amostras classificadas como potenciais outliers, oferecendo assim um suporte concreto para processos de inspeção e controle de qualidade em componentes produzidos por **impressão 3D**.

Palavras-chave: PLA, impressão 3D, aprendizado de máquina, defeitos internos.

ABSTRACT

Identifying defective parts in large production volumes is a real challenge faced in current production lines. This project employs a methodology integrating concepts from statistics and artificial intelligence. Experimental data were collected for analysis based on the **KDD (Knowledge Discovery in Databases)** process, which involves structured stages of data selection, preprocessing, transformation, data mining and interpretation.The data were processed using Python scientific libraries, enabling statistical analysis, graphical visualization and machine learning model application. In particular, the **Isolation Forest algorithm** was applied to detect anomalous samples potentially associated with internal defects in the analyzed specimens.

Additionally, a stability analysis via bootstrap resampling was conducted to assess the robustness of samples classified as outliers against variations in the model's training subset, providing an objective confidence measure in the absence of an experimental defect ground truth.Finally, the results demonstrated that the methodology was able to identify relevant relationships between experimental variables and mechanical behavior, while automatically generating a structured CSV list containing the IDs of samples classified as probable outliers, thus providing support for quality inspection in **3D printed components**.

Keywords: PLA, 3D printing, machine learning, internal defects.

1 INTRODUÇÃO

A impressão 3D tem se consolidado no mercado atual como uma tecnologia relevante para a produção de produtos. Tanto em campos industriais ou de varejo, essa inovação vem se destacando através da alta flexibilidade, facilidade no transporte e por apresentar preços muitas vezes mais atrativos (Centro Paula Souza, 2023; Brazilian Journal of Development, 2024). Dentre os materiais mais empregados no meio, podemos destacar o popularmente conhecido como plástico PLA ou o poli(ácido lático) que se diferencia devido à alta compatibilidade de propriedades mecânicas e térmicas para projetos menos extremos, acessibilidade e biodegradabilidade,pois esse biopolímero possui origem em fontes renováveis como milho, cana-de-açúcar e outros materiais ricos em amido (Lemos & Martins, 2014).

No entanto, mesmo com tais vantagens, componentes fabricados em PLA também podem apresentar defeitos internos ou falhas estruturais associadas ao processo de fabricação. No contexto deste estudo, algumas amostras foram produzidas com variações intencionais no processo de impressão, introduzidas pelo responsável pela fabricação das peças. Essas alterações não foram previamente informadas aos pesquisadores responsáveis pela análise dos dados, com o objetivo de avaliar a capacidade dos métodos estatísticos e de mineração de dados em identificar comportamentos anômalos nas amostras. Defeitos desse tipo, quando presentes, podem resultar em queda no desempenho mecânico das peças e impactar processos de controle de qualidade em sistemas de manufatura aditiva (Centro Paula Souza, 2023). Através de ensaios mecânicos, colhemos informações fundamentais com o intuito de analisar o comportamento estrutural das amostras, o que tornou evidente que pequenas análises isoladas são insuficientes tanto do ponto de vista prático quanto estatístico para identificação de padrões mais complexos.

Como resposta, utilizamos o processo **KDD (Knowledge Discovery in Databases)** para incorporar etapas consolidadas como seleção de dados, pré-processamento, transformação, mineração de dados e interpretação dos resultados (Han, Kamber & Pei, 2012; Cavalcante, 2019). O uso de técnicas de **data mining** e **aprendizado de máquina** tem se mostrado uma abordagem promissora para a extração de conhecimento em conjuntos de dados experimentais complexos (Fontana, 2018; Cavalcante, 2019). Dessa forma, esse trabalho tem como objetivo

de documentar uma metodologia baseada em análise estatística, aprendizado de máquina e mineração de dados para a identificação de amostras cilíndricas de PLA com possíveis defeitos internos.

2 REVISÃO BIBLIOGRÁFICA

2.1 Impressão 3D e Propriedades do PLA

Materiais produzidos por manufatura aditiva apresentam variabilidade nas propriedades mecânicas devido a condições de processamento, como temperatura, velocidade de deposição, direção de impressão e presença de defeitos internos. Estudos indicam que inconsistências estruturais geradas durante o processo de deposição podem resultar em comportamento mecânico não homogêneo (Brazilian Journal of Development, 2024; Centro Paula Souza, 2023).

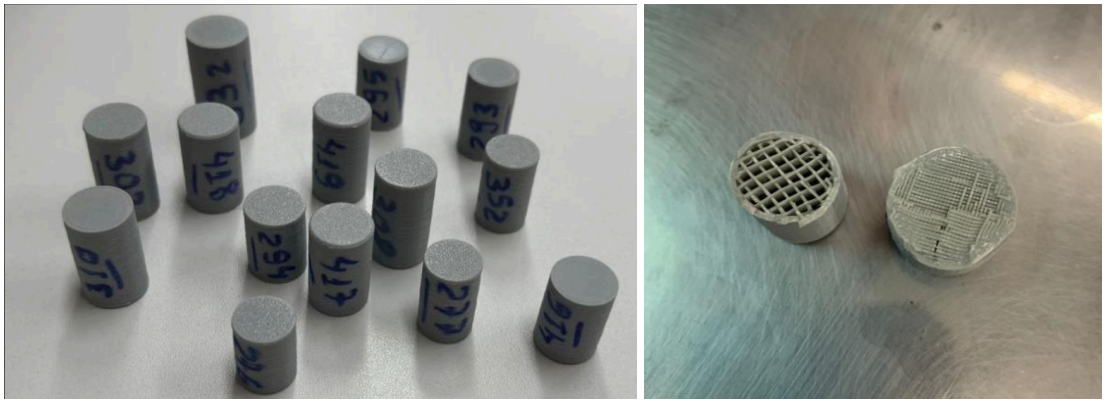


Figura 1 : Amostras cilíndricas de PLA
Figura 2 : Diferença entre amostra defeituosa e legítima
Fonte : Projeto CIDA: Avaliação e análise das propriedades do PLA. Relatório técnico. 2024.

2.2 Análise Estatística de Dados Experimentais

A análise estatística clássica fornece ferramentas para caracterização de dados experimentais. Estatísticas descritivas, histogramas, correlação e regressão linear são amplamente utilizados para compreender relações entre variáveis e medir a força dessas relações. A regressão linear permite estimar uma relação média entre variáveis enquanto a análise de resíduos pode indicar comportamentos atípicos ou desvios estruturais nos dados experimentais (Bussab & Morettin, 2013).

2.3 KDD e Mineração de Dados

O processo de Knowledge Discovery in Databases (KDD) consiste em etapas sistemáticas de seleção, pré-processamento, transformação, aplicação de métodos de mineração de dados e avaliação dos padrões encontrados (Han, Kamber & Pei, 2012; Cavalcante, 2019). A mineração de dados refere-se à extração de padrões úteis em grandes conjuntos de dados utilizando técnicas estatísticas e algoritmos de aprendizado de máquina (Han, Kamber & Pei, 2012).

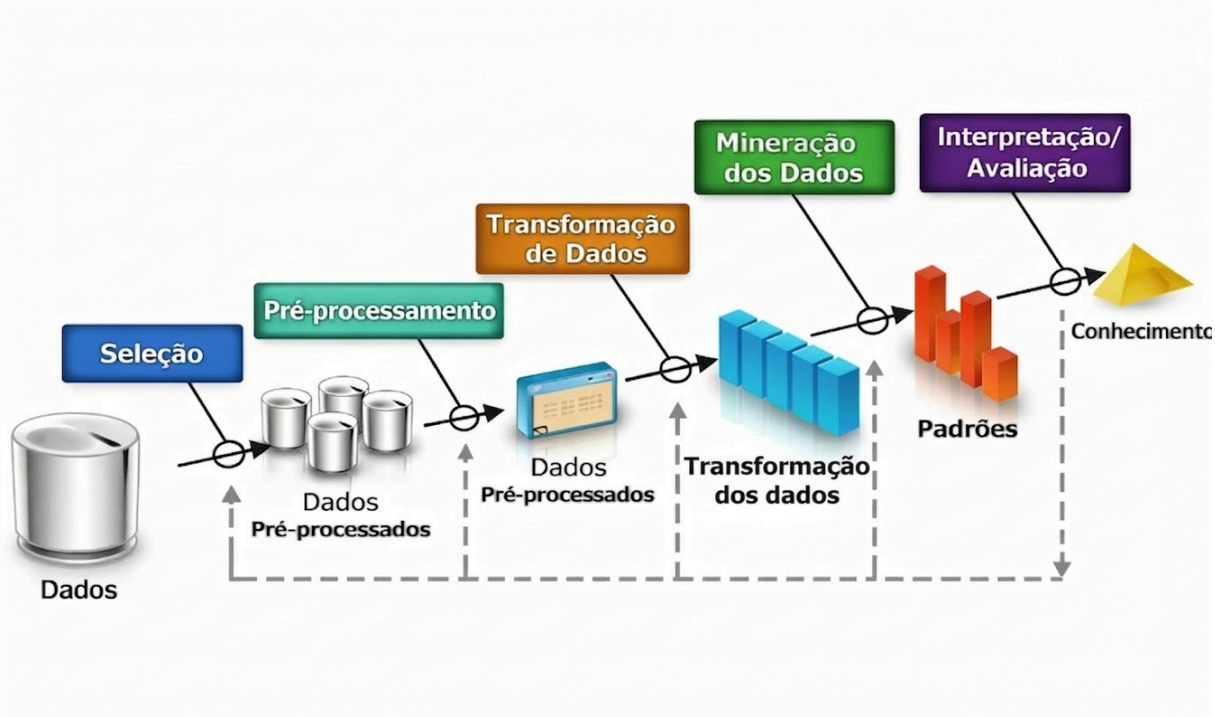


Figura 3 : Ilustração processo KDD

Fonte : Etapas do processo de KDD. Fonte: Adaptado de "From Data Mining to Knowledge Discovery in Databases" de Usama Fayyad

2.4 Aprendizado de Máquina Não Supervisionado para Detecção de Anomalias

Algoritmos de aprendizado de máquina podem ser aplicados para identificar padrões atípicos em conjuntos de dados experimentais. Técnicas de detecção de anomalias permitem identificar observações raras que apresentam comportamento distinto do padrão geral dos dados, auxiliando na identificação de possíveis falhas ou defeitos estruturais (Fontana, 2018; Cavalcante, 2019).

2.5 Validação de Modelos Não Supervisionados na Ausência de Gabarito

Um dos principais desafios na aplicação de algoritmos de detecção de anomalias em contextos experimentais reais é a ausência de rótulos verdadeiros (ground truth) que permitam calcular diretamente métricas de desempenho, como taxas de falsos positivos e falsos negativos. Nesses cenários, técnicas de reamostragem, como o bootstrap, têm sido utilizadas como estratégia de validação indireta, permitindo avaliar a estabilidade e a robustez das classificações produzidas pelo modelo frente a variações no conjunto de dados de treinamento (Efron & Tibshirani, 1994). A ideia central é que padrões genuinamente anômalos tendem a ser identificados de forma consistente independentemente da amostra de treinamento utilizada, enquanto classificações sensíveis a variações

3 METODOLOGIA

A metodologia deste estudo foi estruturada com base no processo KDD (Knowledge Discovery in Databases), que organiza a extração de conhecimento a partir de bases de dados em etapas sistemáticas de preparação, processamento e análise (Han, Kamber & Pei, 2012; Cavalcante, 2019).Para garantir a reprodutibilidade do estudo, o procedimento experimental e analítico foi dividido nas etapas descritas a seguir.

3.1 Coleta e organização dos dados

Os dados utilizados neste estudo foram provenientes de ensaios das amostras cilíndricas de PLA com utensílios como balanças de precisão de 0,1g ,paquímetros e uma máquina de ensaio de tração Kratos, o critério utilizado para se determinar a resistência mecânica da peça foi o início da deformação plástica, identificado pelo fim da região linear do gráfico.Os dados foram organizados inicialmente em uma planilha e posteriormente exportados para um arquivo no formato CSV para processamento computacional.

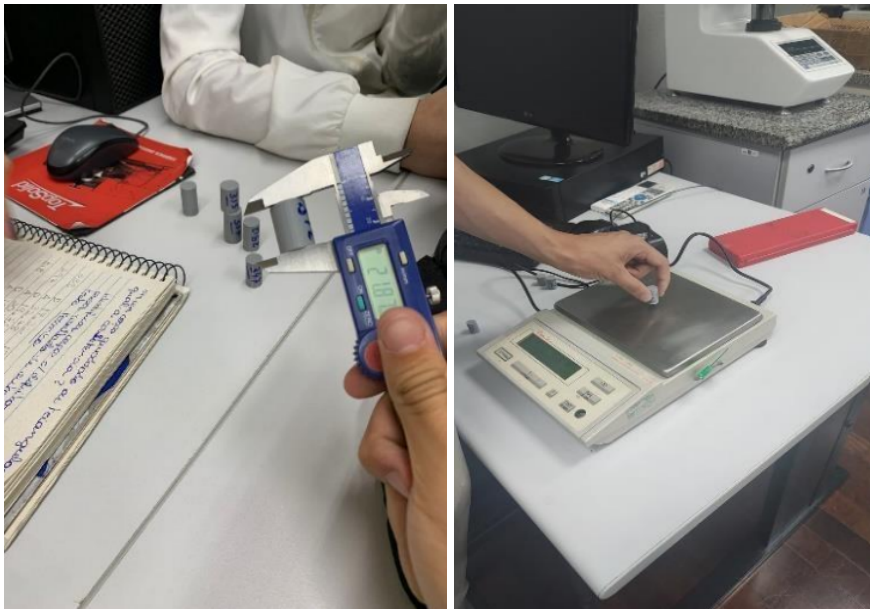


Figura 4 : Medições de altura e diâmetro
Figura 5 : Medições da massa

Fonte : Projeto CIDA: Avaliação e análise das propriedades do PLA. Relatório técnico. 2024.

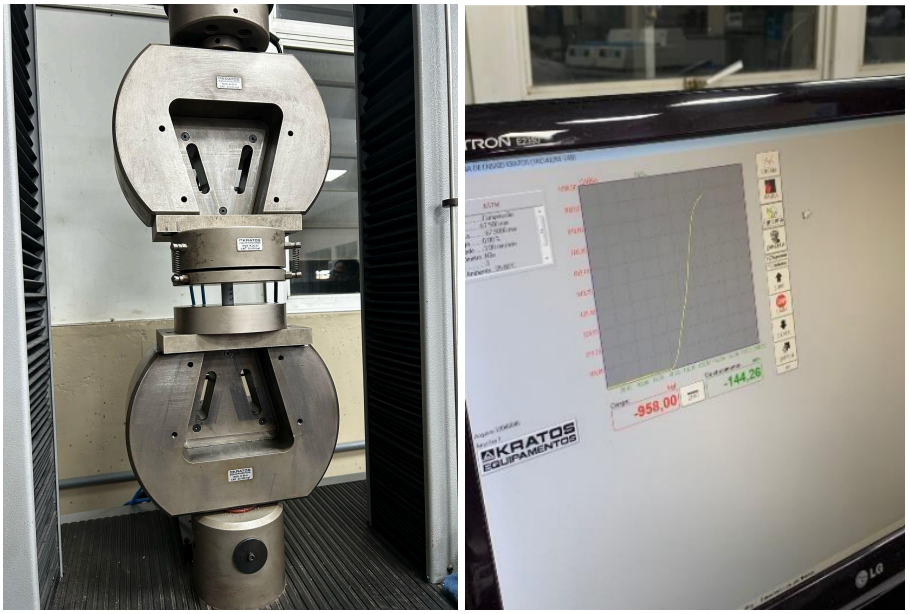


Figura 6 e 7 : Teste de resistência mecânica

Fonte : Projeto CIDA: Avaliação e análise das propriedades do PLA. Relatório técnico. 2024.

3.2 Preparação e limpeza dos dados

A etapa de pré-processamento consistiu na verificação de inconsistências nos dados experimentais, incluindo: lidar com registros incompletos, verificação de valores inconsistentes, padronização dos nomes das variáveis.Após essa etapa, o conjunto de dados foi importado para o ambiente de programação Python para realização das análises.

3.3 Ambiente computacional e bibliotecas utilizadas

As análises foram realizadas utilizando a linguagem de programação Python, amplamente utilizada em projetos de ciência de dados e mineração de dados.Foram utilizadas bibliotecas científicas para manipulação de dados, análise estatísticas, geração de gráficos e aplicações de algoritmos de machine learning, entre elas : numpy, matplotlib,pandas,seaborn e scikit-learn.

3.4 Análise estatística exploratória

Inicialmente foi realizada uma análise exploratória dos dados com o objetivo de compreender o comportamento geral das variáveis experimentais.

Foram utilizadas técnicas como cálculo de estatísticas descritivas como média,moda e mediana, análise da distribuição das variáveis e a construção de gráficos exploratórios.Essas análises permitem identificar padrões iniciais e possíveis inconsistências nos dados experimentais (Bussab & Morettin, 2013).

3.5 Análise de correlação e regressão linear

Para investigar relações entre variáveis físicas das amostras, foi construída uma matriz de correlação entre os parâmetros experimentais.Além disso, foi ajustado um modelo de regressão linear simples entre massa e resistência mecânica das amostras, permitindo avaliar tendências gerais do comportamento estrutural.

3.6 Análise de resíduos

Após o ajuste do modelo de regressão linear, foi realizada uma análise de resíduos com o objetivo de identificar amostras que apresentam comportamento significativamente distinto da tendência média observada.Essa abordagem permite identificar possíveis anomalias estruturais ou inconsistências nos resultados experimentais.

3.7 Detecção de anomalias

Por fim, foi aplicado um algoritmo de detecção de anomalias baseado em aprendizado de máquina para identificar amostras com comportamento atípico no conjunto de dados.Esse tipo de abordagem permite detectar observações raras ou inconsistentes em bases experimentais complexas (Fontana, 2018; Han, Kamber & Pei, 2012).O resultado dessa etapa foi a geração de uma listagem contendo os identificadores das amostras classificadas como potenciais outliers.

3.8 Análise de estabilidade dos outliers (validação bootstrap)

Uma limitação inerente à aplicação de algoritmos de detecção de anomalias em contextos experimentais é a ausência de um gabarito real que indique, com certeza, quais amostras efetivamente possuem defeitos internos. No caso deste estudo, embora algumas amostras tenham sido produzidas intencionalmente com variações no processo de impressão, a equipe responsável pela análise de dados não teve acesso prévio ou posterior a essa identificação, caracterizando um desenho experimental cego do ponto de vista analítico. Dessa forma, não foi possível calcular diretamente a taxa de falsos positivos e falsos negativos do modelo empregado.

Como estratégia de validação indireta, foi conduzida uma análise de estabilidade das classificações produzidas pelo algoritmo Isolation Forest por meio de reamostragem bootstrap. O procedimento consistiu em treinar o modelo repetidamente (200 iterações) sobre subconjuntos de dados obtidos por amostragem com reposição (bootstrap) do conjunto original, mantendo os mesmos parâmetros da análise principal (contamination = 0,15). Em cada iteração, o modelo treinado foi aplicado sobre o conjunto de dados original completo, registrando-se, para cada amostra, se esta foi ou não classificada como outlier naquela rodada.

A partir desse procedimento, foi calculada a frequência relativa com que cada amostra foi classificada como anômala ao longo das 200 iterações, sendo essa frequência interpretada como uma medida de estabilidade da classificação. Amostras que foram consistentemente identificadas como outliers em praticamente todas as rodadas (frequência igual ou superior a 90%) foram consideradas outliers robustos, com baixo risco de se tratarem de falsos positivos decorrentes de variações normais do processo de impressão.

Amostras identificadas como outliers com frequência entre 50% e 90% foram classificadas como casos de fronteira, indicando maior incerteza. Já amostras classificadas como outliers em menos de 50% das rodadas, mas que ainda assim apareceram como outliers na análise principal, foram consideradas de baixa consistência, sugerindo maior probabilidade de se tratarem de falsos positivos associados à sensibilidade do modelo a variações amostrais.

4 RESULTADO E DISCUSSÃO

4.1 Distribuição e comportamento geral das amostras

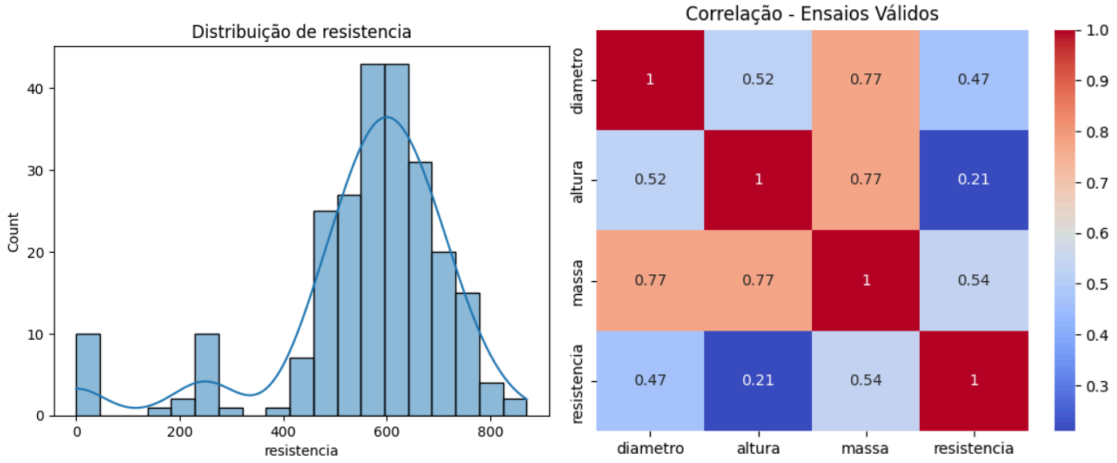


Figura 8 : Distribuição da resistência das amostras
Figura 9 : Matriz de correlação entre variáveis experimentais

Fonte : Autoria própria

A análise inicial dos dados foi realizada por meio da distribuição da resistência mecânica das amostras e da matriz de correlação entre as variáveis experimentais.A distribuição da resistência permite observar a dispersão dos valores obtidos nos ensaios mecânicos, evidenciando a presença de variações mesmo entre amostras com características geométricas semelhantes. Essa variabilidade nos aponta a imperfeições no processo de fabricação ou à presença de defeitos internos.Complementarmente, a matriz de correlação permite avaliar a intensidade das relações entre as variáveis medidas no experimento. A análise indica a existência de correlações positivas entre algumas variáveis físicas e a resistência mecânica das amostras, sugerindo que determinadas características estruturais podem influenciar diretamente no desempenho mecânico, no caso, a variável que mais está correlacionada a resistência é a massa. Essas análises exploratórias fornecem uma visão inicial do comportamento dos dados e orientam as etapas posteriores de modelagem estatística.

4.2 Relação entre massa e resistência das amostras

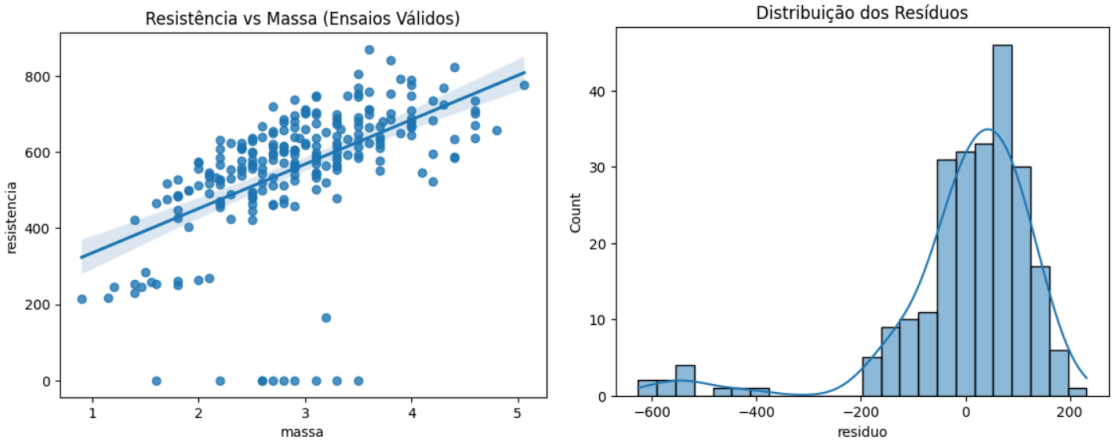


Figura 10 : Regressão linear entre massa e resistência
Figura 11 : Distribuição dos resíduos da regressão

Fonte : Autoria própria

A relação entre massa e resistência mecânica foi investigada por meio de um modelo de regressão linear simples. O gráfico de regressão indica uma tendência geral de aumento da resistência com o aumento da massa das amostras. Essa relação sugere que pequenas variações estruturais nas peças podem influenciar seu comportamento mecânico. Entretanto, a análise dos resíduos revela a presença de amostras que apresentam comportamento significativamente distinto da tendência média observada. Esses desvios podem indicar variações estruturais internas ou defeitos de fabricação que não são identificáveis apenas por inspeção visual. A análise conjunta da regressão e dos resíduos permite identificar padrões estruturais e possíveis inconsistências nos dados experimentais.

4.3 Identificação de amostras anômalas

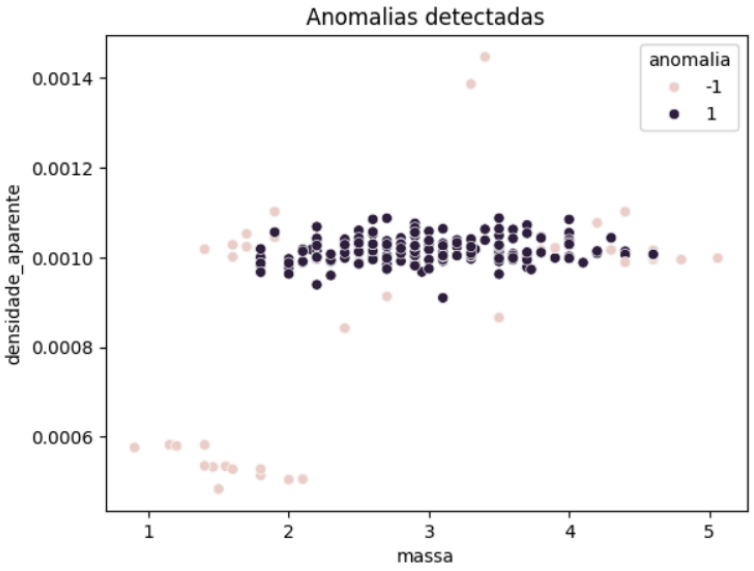


Figura 12 : Identificação de amostras anômalas

Fonte : Autoria própria

Para aprofundar a investigação dos comportamentos atípicos observados na análise estatística, foi aplicado um algoritmo de detecção de anomalias baseado em aprendizado de máquina, o Isolation Forest.O modelo permitiu identificar automaticamente um conjunto de amostras com comportamento significativamente distinto em relação ao padrão geral do conjunto de dados.Essas amostras foram classificadas como potenciais outliers e registradas em uma listagem estruturada contendo seus respectivos identificadores. Essa informação pode ser utilizada para direcionar análises experimentais adicionais ou inspeções estruturais mais detalhadas.A aplicação de técnicas de mineração de dados nesse contexto demonstra o potencial da integração entre métodos estatísticos e inteligência artificial para apoiar processos de controle de qualidade em sistemas de manufatura aditiva.

4.4 Análise de estabilidade dos outliers: avaliação de falsos positivos

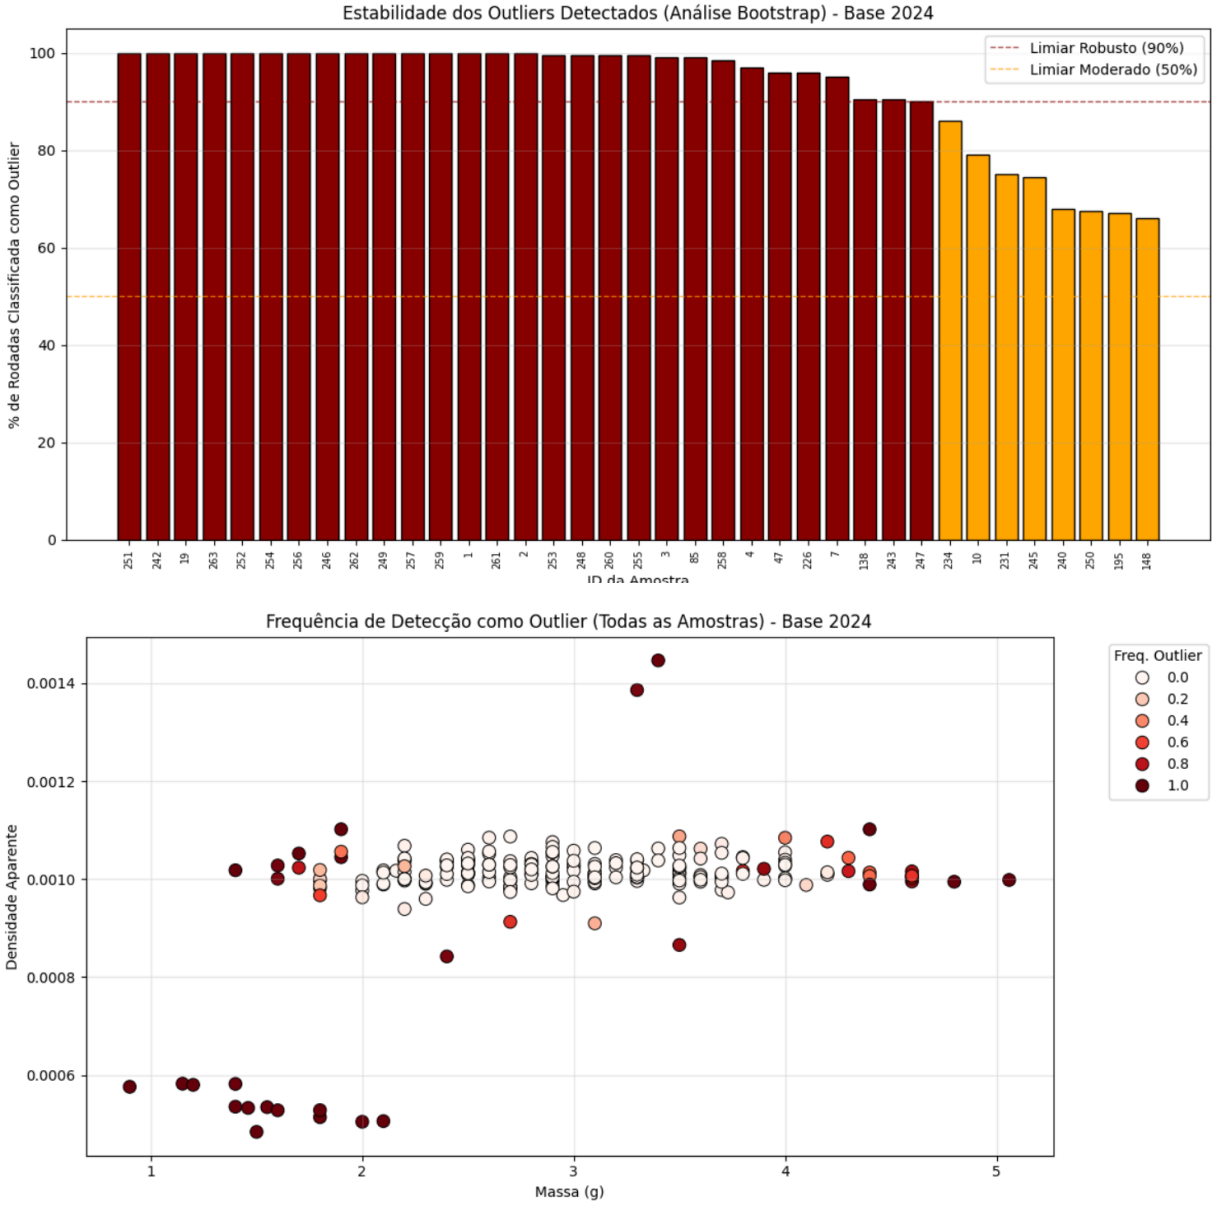


Figura 13 : Estabilidade dos outliers detectados (análise bootstrap)
Figura 14 : Frequência de detecção como outlier de todas as amostras
Fonte : Autoria própria

Em resposta à necessidade de avaliar a robustez das amostras classificadas como outliers frente a possíveis variações normais do processo de impressão 3D, foi conduzida a análise de estabilidade descrita na seção 3.8. Das 37 amostras classificadas como outliers na análise original com o algoritmo Isolation Forest, 29 (78.4%) amostras apresentaram estabilidade igual ou superior a 90% ao longo das 200 reamostragens bootstrap, sendo consideradas outliers robustos. Outras 21.6% das amostras apresentaram estabilidade entre 50% e 90%, caracterizando casos de fronteira que demandam maior cautela na interpretação. Por fim, 0% das amostras classificadas como outliers na análise original apresentaram estabilidade inferior a 50% ao longo das reamostragens, indicando maior sensibilidade do modelo a

variações no subconjunto de treinamento e, consequentemente, maior probabilidade de tratarem-se de falsos positivos associados a variações normais do processo de fabricação, e não necessariamente a defeitos intencionais.

Esses resultados indicam que, embora não seja possível calcular a taxa exata de falsos positivos do modelo na ausência de um gabarito experimental de defeitos, a maioria esmagadora das amostras classificadas como outliers apresentou-se estatisticamente consistente frente à reamostragem dos dados, reforçando a confiabilidade da metodologia empregada. As amostras identificadas com baixa consistência devem ser tratadas com cautela adicional, sendo recomendável, em trabalhos futuros, sua validação por meio de métodos de inspeção que permitiriam confirmar com maior segurança a presença ou ausência de defeitos internos.

Do ponto de vista prático, essa análise de estabilidade representa uma contribuição metodológica relevante para estudos que aplicam algoritmos de detecção de anomalias não supervisionados em contextos experimentais sem gabarito, oferecendo uma medida objetiva e reprodutível de confiança nas classificações produzidas, em substituição a uma validação absoluta que, neste caso, não foi viável.

5 BIBLIOGRAFIA

Usama Fayyad,Gregory Piatetsky-Shapiro,Padhraic Smyth disponível em : https://ojs.aaai.org/aimagazine/index.php/aimagazine/article/view/1230

LEMOS, Alessandra Luiza de; MARTINS, Ricardo M. Desenvolvimento e caracterização de compósitos poliméricos à base de poli(ácido lático) e fibras naturais. *Polímeros: Ciência e Tecnologia*, v. 24, n. 2, 2014. Disponível em:https://revistapolimeros.org.br/doi/10.4322/polimeros.2014.047

FERNANDES, Fernando Timóteo; CHIAVEGATTO FILHO, Alexandre Dias Porto. Perspectivas do uso de mineração de dados e aprendizado de máquina em saúde e segurança no trabalho. Revista Brasileira de Saúde Ocupacional. Disponível em: https://www.scielo.br/j/rbso/a/NgxW5qxzQWhcD4KrTHLxxGG/?lang=pt

FONTANA, José Marcelo. Aprendizado de Máquina – Apostila didática. Universidade Federal de Santa Catarina (UFSC). Disponível em: https://fontana.paginas.ufsc.br/files/2018/03/apostila_ML.pdf

CAVALCANTE, Alexandre Araripe. Mineração de dados aplicada à análise de grandes bases de dados. Tese de Doutorado. Universidade Federal da Bahia. Disponível em: https://repositorio.ufba.br/bitstream/ri/37028/1/Tese%20de%20Doutorado%20de%20Alexandre%20Araripe%20Cavalcante.pdf

ASSOCIAÇÃO BRASILEIRA DE EDUCAÇÃO EM ENGENHARIA (ABENGE). Artigo técnico publicado nos anais da ABENGE. Disponível em: https://abenge.org.br/sis_artigo_com_capa.php/?cod_trab=5391

OPEN SCIENCE FRAMEWORK (OSF). Dataset ou material de pesquisa disponível no repositório científico OSF. Disponível em: https://osf.io/y9qu8/

OPEN SCIENCE FRAMEWORK (OSF). Material científico disponível no repositório OSF. Disponível em: https://osf.io/284z9/

HAN, Jiawei; KAMBER, Micheline; PEI, Jian. Data Mining: Concepts and Techniques. Morgan Kaufmann. Disponível em: https://books.google.com.br/books?hl=pt-BR&lr=&id=HN6sCQAAQBAJ&oi=fnd&pg=PT16&dq=Data+mining

BRAZILIAN JOURNAL OF DEVELOPMENT. Artigo científico publicado na revista Brazilian Journal of Development. Disponível em: https://ojs.brazilianjournals.com.br/ojs/index.php/BRJD/article/view/74593

CENTRO PAULA SOUZA. Publicação acadêmica disponível no repositório institucional RIC-CPS. Disponível em: http://ric-cps.eastus2.cloudapp.azure.com/handle/123456789/23158

BUSSAB, Wilton de Oliveira; MORETTIN, Pedro Alberto. Estatística Básica / Análises estatísticas aplicadas. São Paulo: Saraiva. Disponível em: https://books.google.com.br/books?hl=pt-BR&lr=&id=sBc6EAAAQBAJ&oi=fnd&pg=PT15

COSTA, Isaque Carlos; CASTRO, André Vinícius de; BRAGA, Gabriela Pereira. Projeto CIDA: Avaliação e análise das propriedades do PLA. Relatório técnico. 2024.