Sistema para Detecção de Vazamentos em Plantas EletroPneumáticas baseado em Machine Learning

1st Erick Toshio Yamamoto
Pós-Graduação em Engenharia da Informação (PPGINF)
Universidade Federal do ABC (UFABC)
Santo André, Brasil
erick.yamamoto@ufabc.edu.com.br

2nd Ricardo Suyama
Pós-Graduação em Engenharia da Informação (PPGINF)
Universidade Federal do ABC (UFABC)
Santo André, Brasil
ricardo.suyama@ufabc.edu.com.br

2025 16th IEEE International Conference on Industry Applications (INDUSCON) | 979-8-3315-5837-6/25/$31.00 ©2025 IEEE | DOI: 10.1109/INDUSCON66435.2025.11241572

***Abstract*—Este artigo propõe uma abordagem eficiente para a detecção de vazamentos em plantas eletropneumáticos, utilizando algoritmos de aprendizado de máquina — *Decision Tree* (DT), *Random Forest* (RF), *Multi-Layer Perceptron* (MLP), *Extreme Learning Machine* (ELM) e *Echo State Network* (ESN). Com base na aquisição de sinais de pressão em diferentes condições operacionais, as séries temporais foram segmentadas e processadas, extraindo de atributos discriminativos com baixo custo computacional utilizando a biblioteca TSFEL. Os modelos foram avaliados quanto à acurácia, tempo de inferência e viabilidade de implementação embarcada. Os resultados evidenciam que modelos como o ELM apresentam alto desempenho mesmo em dispositivos com recursos limitados, como o ESP32, combinando robustez com baixa latência. A investigação demonstra o potencial de soluções acessíveis e confiáveis para manutenção preditiva em ambientes da Indústria 4.0, com foco em inteligência embarcada e custo reduzido.**

***Index Terms*—TSFEL, Manutenção Preditiva, Aprendizado de Máquina, Detecção de Vazamentos, ELM, ESN, Sistemas Embarcados.**

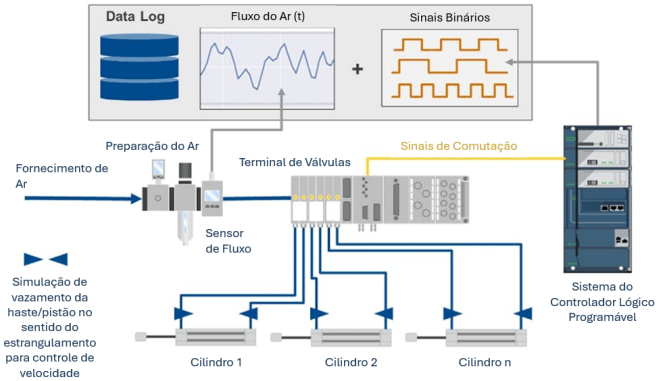


Fig. 1. Sistema Eletropneumático comandado e monitorado por CLP (Controlador Lógico Programável). Fonte: Adaptado de [19]

I. Introdução

Os sistemas eletropneumáticos são amplamente utilizados em ambientes industriais devido à sua simplicidade, baixo custo de operação, alta confiabilidade e capacidade de realizar movimentos rápidos e precisos. Presentes em linhas de montagem, sistemas de transporte, dispositivos de automação e controle, esses sistemas desempenham um papel central em diversos setores como automobilístico, alimentício, farmacêutico e eletrônico. Sua popularidade também se deve à facilidade de integração com controladores programáveis e sensores industriais, tornando-os componentes essenciais na transição para ambientes automatizados e conectados da Indústria 4.0.

Combinando componentes elétricos e pneumáticos, tais sistema são amplamente utilizados em aplicações que exigem controle preciso de atuadores. São compostos por válvulas eletropneumáticas, responsáveis por controlar o fluxo de ar comprimido, sensores que monitoram parâmetros como pressão e vazão, e controladores programáveis (CLPs) que coordenam a operação.

A manutenção preventiva desses sistemas envolve inspeções regulares em válvulas e tubulações, limpeza de componentes e recalibração de sensores, enquanto os sistemas puramente elétricos demandam verificação de circuitos eletrônicos e testes de software [3]–[5]. Essa diferença evidencia a necessidade de estratégias específicas de manutenção conforme a natureza do sistema. A Figura 1 ilustra um exemplo típico de sistema eletropneumático com CLP.

Apesar de sua ampla adoção, a eficiência energética desses sistemas está fortemente condicionada à integridade de seus componentes. Vazamentos de ar comprimido, ainda que frequentemente subestimados, representam perdas significativas de energia e aumentos consideráveis nos custos operacionais. Segundo estimativas da ISO 8573, até 30% do ar comprimido pode ser desperdiçado em função de falhas não detectadas [1].

Os métodos tradicionais de inspeção, como escuta auditiva ou aplicação de espuma, são ineficazes em ambientes industriais ruidosos ou com acesso restrito. Neste trabalho, o problema do ruído ambiental é contornado por meio da aquisição de sinais diretamente do sensor de pressão acoplado ao sistema, evitando a dependência de sinais acústicos ou visuais sujeitos à interferência externa. Com isso, a análise passa a se concentrar em variações internas do sistema pneumático, permitindo maior robustez mesmo em cenários ruidosos ou de difícil acesso. Neste contexto, abordagens baseadas em inteligência artificial (IA) e aprendizado de máquina (ML) têm se destacado por oferecerem uma análise automatizada e precisa dos sinais dos sensores [2], [20], [33],

Este trabalho contou com o apoio da Coordenação de Aperfeiçoamento de Pessoal de Nível Superior - Brasil (CAPES) – Código de Financiamento 001, da Fundação de Amparo à Pesquisa do Estado de São Paulo (FAPESP) - proc.#2020/09838-0, e do Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq) - proc. #311380/2021-2.

Authorized licensed use limited to: Universidade Estadual de Campinas. Downloaded on October 04,2026 at 19:37:19 UTC from IEEE Xplore. Restrictions apply.

[36].

Dessa forma, o presente artigo propõe uma abordagem que, utilizando exclusivamente os sinais de pressão adquiridos em um único ponto do circuito, permite a inferência automática da presença e da localização de vazamentos em sistemas eletropneumáticos. Para isso, são utilizados modelos clássicos de aprendizado de máquina, treinados com atributos extraídos automaticamente desses sinais. O objetivo não é apenas propor o algoritmo, mas também avaliar a viabilidade da aplicação desses modelos em dispositivos embarcados de baixo custo, como o ESP32, possibilitando diagnósticos em tempo real voltados à manutenção preditiva.

Para isso, o artigo foi estruturado da seguinte forma. Na Seção II é apresentado um histórico sobre a evolução da manutenção industrial, abordando seus principais tipos e destacando o papel crescente das abordagens preditiva e prescritiva. A Seção III descreve o processo de aquisição e processamento dos dados, detalhando o circuito de leitura e a metodologia de extração de atributos. Na Seção IV, são discutidos os modelos clássicos de aprendizado de máquina empregados, com ênfase na viabilidade de aplicação embarcada. A Seção V trata da integração física do sistema proposto com a plataforma ESP32. A Seção VI apresenta os resultados experimentais, e, finalmente, na Seção VII, são apresentadas as conclusões e perspectivas futuras.

II. Tecnologias Inteligentes Aplicadas à Manutenção Industrial

A manutenção de equipamentos desempenha um papel crucial na confiabilidade e na eficiência dos processos produtivos. Com o avanço da tecnologia e a crescente demanda por disponibilidade e segurança operacional, as estratégias de manutenção vêm passando por transformações significativas ao longo do tempo. Esse processo evolutivo reflete a busca contínua por soluções mais eficazes, econômicas e inteligentes para garantir o desempenho ideal dos ativos industriais [8].

Nesse contexto, é possível identificar ao menos quatro estágios no desenvolvimento das estratégias de manutenção industrial, cada um refletindo o nível de maturidade tecnológica:

- **Manutenção Corretiva**: Este tipo de manutenção envolve o reparo de uma máquina após uma falha. O objetivo é tornar a máquina o mais rápido possível para funcionar normalmente e reduzir o tempo de inatividade não planejada. No entanto, a manutenção corretiva pode ser cara e levar a períodos de inatividade prolongados;
- **Manutenção Preventiva**: Mesmo quando não há sinais imediatos de falha, as máquinas são inspecionadas regularmente e mantidas de acordo com um cronograma pré-estabelecido durante a manutenção preventiva. O objetivo é evitar falhas e prolongar a vida útil da máquina por meio da substituição de peças desgastadas ou ajustes feitos antes da falha e um dos principais métodos de acompanhamento é o CMMS, sendo encontrado com mais detalhes em [6];
- **Manutenção Preditiva**: A manutenção preditiva, conhecida como CBMS [7], inclui o uso de sensores e técnicas de análise de dados para monitorar continuamente o estado das máquinas para identificar falhas antes que elas ocorram. Isso permite que você programe intervenções de manutenção com base em sinais de falha ou sinais de falha, reduzindo o tempo de inatividade e reduzindo os custos de manutenção;
- **Manutenção Prescritiva**: A manutenção prescritiva usa análise de dados, aprendizado de máquina e algoritmos de IA para prescrever ações de manutenção com base em dados em tempo real sobre o estado e o desempenho das máquinas [11], [12]. Esta abordagem vai além da manutenção preditiva e sugere ações específicas para evitar e otimizar o desempenho das máquinas ou evitar falhas iminentes.

A transição das estratégias tradicionais de manutenção — corretiva e preventiva — para abordagens mais avançadas, como a preditiva e a prescritiva, está diretamente associada à incorporação de tecnologias baseadas em dados, com destaque para o uso de aprendizado de máquina. Essas abordagens dependem da coleta contínua de sinais de sensores, da extração eficiente de atributos e da aplicação de modelos capazes de identificar padrões sutis indicativos de falhas iminentes ou condições operacionais subótimas. A aplicação de técnicas de aprendizado de máquina, portanto, não apenas viabiliza essas novas formas de manutenção, como também representa um elemento central para sua efetividade.

Nesse contexto, o uso de aprendizado de máquina tem sido amplamente investigado como uma ferramenta promissora para a detecção de falhas em sistemas industriais. Técnicas de classificação supervisionada, como *Decision Trees* (DT) e *Random Forests* (RF), têm demonstrado bom desempenho na identificação de padrões anômalos em sinais provenientes de sensores industriais, devido à sua robustez frente a ruídos e à capacidade de lidar com variáveis heterogêneas [21], [33]. Paralelamente, redes neurais multicamadas (*Multilayer Perceptrons*, MLP) vêm sendo empregadas com sucesso na modelagem de relações não lineares em séries temporais, permitindo capturar dinâmicas complexas de sistemas em operação contínua [22], [38].

Outros modelos, como Extreme Learning Machines (ELM) e Echo State Networks (ESN), embora não sejam recentes em termos conceituais, continuam a ganhar destaque em aplicações embarcadas modernas. Estudos recentes demonstram sua eficácia em cenários como caracterização de carga de trabalho [41], [42], previsão de séries temporais em dispositivos de borda [43] e implementação eficiente em hardware dedicado, como FPGAs [44], evidenciando sua capacidade de treinamento rápido e baixo custo computacional — características fundamentais para sistemas com restrições de recursos.

Além dos avanços nos algoritmos preditivos, a etapa de engenharia de atributos continua sendo um fator determinante para o desempenho dos modelos. Diversos estudos recentes têm se dedicado à otimização desse processo em contextos industriais, propondo técnicas híbridas e abordagens interpretáveis para seleção de atributos [34], [35], [37]. Nesse cenário, bibliotecas como a TSFEL destaca-se como uma ferramenta robusta para extração automática de atributos em séries temporais, permitindo uma avaliação explícita da complexidade computacional dos atributos extraídos — aspecto essencial para aplicações embarcadas em ambientes

Authorized licensed use limited to: Universidade Estadual de Campinas. Downloaded on October 04,2026 at 19:37:19 UTC from IEEE Xplore. Restrictions apply.

industriais com restrições de recursos [23].

Apesar dos avanços observados na literatura, ainda são escassos os estudos que exploram de forma integrada a aplicação de modelos preditivos clássicos em cenários embarcados voltados à detecção de falhas específicas, como vazamentos em sistemas eletropneumáticos. Dessa forma, este trabalho propõe preencher essa lacuna por meio do desenvolvimento e avaliação de uma abordagem eficiente, com baixo custo computacional, voltada à implementação embarcada de manutenção preditiva em sistemas industriais.

III. Aquisição e Processamento dos Dados

Para o desenvolvimento do trabalho, foi considerado um circuito eletropneumático conforme apresentado na Figura 2, composto por dois atuadores ligados a uma mesma linha de ar comprimido, por meio de duas válvulas independentes. No circuitos é possível simular vazamentos tanto no avanço como no recuo dos atuadores, e um único sensor de pressão está localizado próximo ao compressor que alimenta a linha de ar comprimido.

A hipótese é que seria possível identificar qual a origem do vazamento apenas pelo sinal obtido com o sensor de pressão. Para isso, dados de pressão foram obtidos com um sensor de pressão USP-G41, compatível com ESP32, com conexão G1/4 adaptados para as conexões de 4 mm, faixa de medição de até 1.2 MPa e tensão de operação de 5V. Este sensor é capaz de operar com gases e líquidos, apresentando boa sensibilidade para aplicações industriais de baixa e média pressão. Sua saída analógica proporcional é facilmente interpretada por microcontroladores através de entradas ADC.

Apesar de suas vantagens, o USP-G41 apresenta limitações relacionadas à resolução do sinal e possíveis interferências causadas por ruídos elétricos ou variações térmicas. A calibração e a estabilidade em ambientes ruidosos são fatores críticos que devem ser considerados. Ainda assim, seu custo-benefício e a simplicidade de integração o tornam ideal para protótipos embarcados de detecção de vazamentos.

As medições foram realizadas em três condições distintas:

- **Normal**: ciclo completo de avanço e recuo sem presença de fuga;
- **Vazamento no Avanço**: simulação de escape de ar durante o movimento de extensão do atuador;
- **Vazamento no Recuo**: simulação de fuga durante a retração do atuador.

As leituras foram registradas em arquivos CSV com taxa de amostragem de 100Hz para capturar as variações transientes do sinal. Para cada condição, foram selecionados trechos relevantes dos ciclos de operação com base na análise visual e conhecimento do processo.

O sinal de pressão foi segmentado em janelas deslizantes de 100 amostras, com uma sobreposição de 90 amostras entre janelas consecutivas, o que permite capturar variações sutis do sinal ao longo do tempo, mantendo continuidade entre os segmentos. Cada janela foi normalizada utilizando padronização z-score, garantindo a remoção de tendências e escalas variáveis. Os segmentos normalizados foram armazenados em um vetor tridimensional para futura aplicação em redes neurais, e simultaneamente convertidos em forma matricial para extração de atributos com a biblioteca TSFEL.

Cada condição foi rotulada e utilizada para o treinamento do classificador, com o intuito de diferenciar padrões de operação e anomalias de pressão relacionadas a vazamentos.

A. Circuito de Leitura e Aquisição

O circuito implementado para aquisição dos sinais de pressão utiliza:

- Fonte de alimentação de 5V;
- Sensor USP-G41 com saída analógica (0.5–4.5V);
- ESP32 com resolução ADC de 12 bits (0–4095);
- Código de aquisição que realiza amostragem a cada 10 ms.

A Figura 2 apresenta o esquema elétrico do circuito de leitura.

A Figura 3 ilustra exemplos representativos dos sinais de pressão adquiridos para as diferentes condições simuladas: operação normal, vazamento no avanço e vazamento no recuo. Observa-se que os sinais de avanço e recuo em condição normal apresentam curvas relativamente estáveis e simétricas, com queda e recuperação rápida da pressão ao final do ciclo. Já nas condições com vazamento, a depressão é mais acentuada e a recuperação é mais lenta, com menor estabilidade do platô de pressão. Essas variações são indicativas da perda de ar comprimido no sistema e foram fundamentais para orientar a segmentação e extração de atributos no pipeline de análise.

B. Extração de Atributos

A extração de atributos é uma etapa fundamental para a aplicação de modelos clássicos de aprendizado de máquina, especialmente em cenários onde o modelo precisa ser eficiente e compatível com dispositivos embarcados.

No sistema proposto, cada janela de 100 amostras é transformada em um vetor de atributos extraídos com a biblioteca TSFEL, que fornece um amplo conjunto de atributos, em diferente domínios, conforme descrito na Tabela I, incluindo medidas como média, desvio padrão, curtose e assimetria; os atributos temporais englobam máximos locais, *zero-crossings* e entropia; e os espectrais são derivados da transformada de Fourier e de Wavelets. A escolha pelo TSFEL foi motivada por sua eficiência computacional, documentação abrangente, e compatibilidade com séries temporais de sensores, o que o torna ideal para aplicações embarcadas com restrições de processamento.

TABLE I
Domínios de atributos extraídos pela TSFEL

Domínio	Exemplos de atributos
Estatístico	média, variância, assimetria, etc.
Temporal	energia, *zero crossing*, RMS, etc.
Espectral	pico de frequência, entropia espectral, etc.

A configuração padrão da biblioteca foi mantida para garantir reprodutibilidade e eficiência computacional. A extração foi realizada iterativamente para cada janela, resultando em um único *DataFrame* com centenas de atributos por janela, que foi padronizado e posteriormente utilizado para treinamento e avaliação dos modelos de classificação. O processo geral de extração de atributos é sumarizado pelo Algoritmo 1.

Authorized licensed use limited to: Universidade Estadual de Campinas. Downloaded on October 04,2026 at 19:37:19 UTC from IEEE Xplore. Restrictions apply.

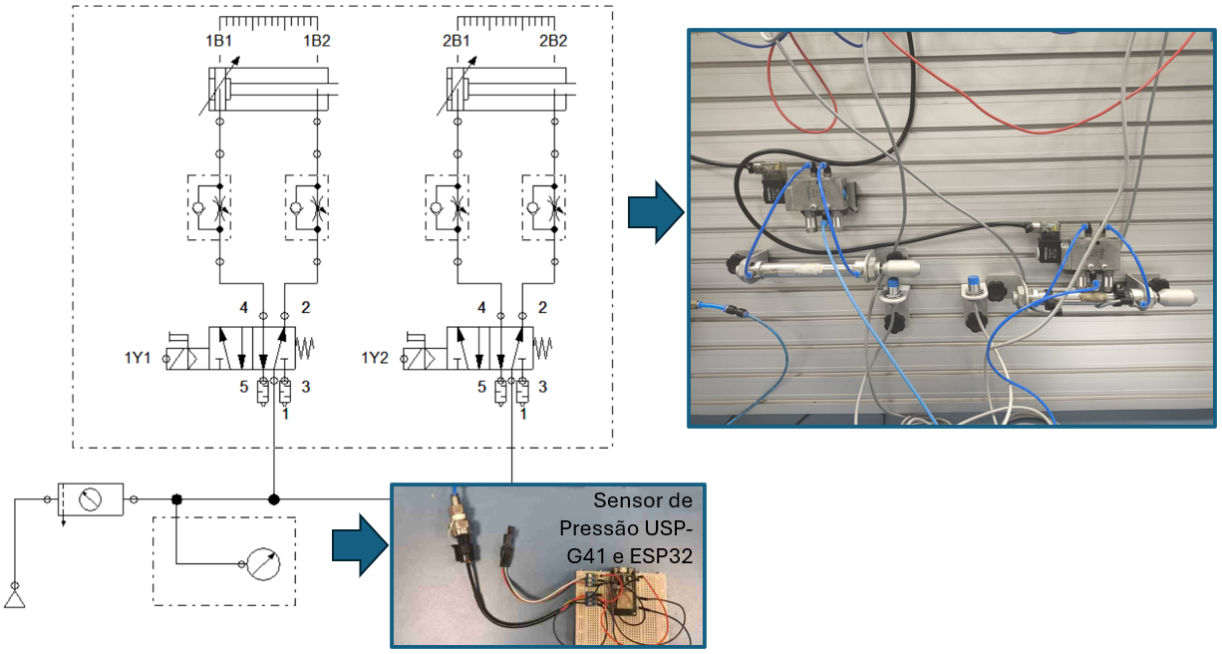


Fig. 2. Circuito de aquisição com sensor USP-G41 e ESP32.

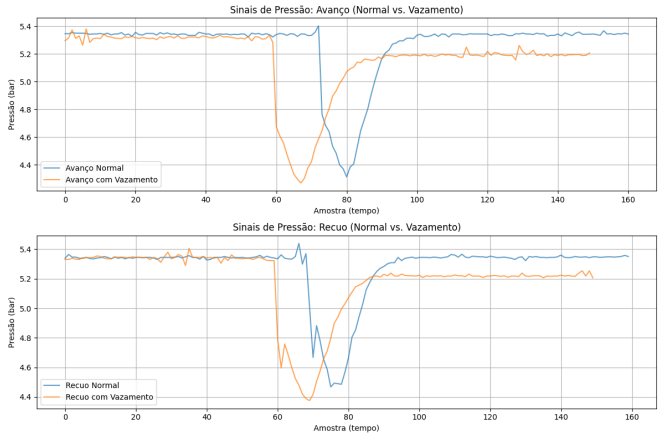


Fig. 3. Sinais de pressão adquiridos para as diferentes condições: comparação entre avanço normal e com vazamento (à esquerda) e recuo normal e com vazamento (à direita).

Algorithm 1 Pseudocódigo da Extração de Atributos

```
Inicializar ESP32
Configurar pino ADC de leitura do sensor USP-G41
while true do
    Ler valor do ADC
    Converter para pressão (mapeamento 0.5-4.5V)
    Armazenar valor na janela de amostragem
    if janela estiver completa then
        Normalizar os dados (z-score)
        Extrair atributos com TSFEL
        Exibir ou transmitir o resultado
    end if
    Aguardar 10 ms
end while
```

C. Classificadores

Com os atributos extraídos e padronizados, diferentes modelos de classificação foram avaliados com foco em aplicação embarcada. Foram considerados modelos que aliam bom desempenho preditivo com baixa complexidade computacional, incluindo *Decision Tree* (DT), *Random Forest* (RF), *Multi-Layer Perceptron* (MLP), *Extreme Learning Machine* (ELM) e *Echo State Network* (ESN) [41], [42], [44]–[49].

O modelo DT foi selecionado por sua simplicidade e interpretabilidade, sendo adequado para aplicaçõoes embarcadas que exigem explicações lógicas [45]. A RF, por sua vez, oferece maior robustez ao *overfitting* e é eficiente em ambientes com ruído [46].

A rede MLP foi utilizada em sua forma rasa (1-2 camadas ocultas) para compatibilidade com microcontroladores [47]. A ELM foi escolhida por sua capacidade de treinamento rápido e inferência eficiente, característica valiosa para sistemas embarcados de baixa potência [41], [42], [48]. Já o modelo ESN, que integra a técnica de *reservoir computing*, se mostrou promissor em capturar padrões dinâmicos do sistema mesmo com custo computacional reduzido [44], [49].

Todos os modelos foram implementados tendo em mente a execução em plataformas como o ESP32, sendo analisados quanto ao desempenho de classificação e aos requisitos computacionais (tempo de inferência, uso de memória).

IV. Implementação em um Sistema Embarcado

O sistema proposto foi integrado fisicamente a uma plataforma ESP32, que realiza a leitura dos sinais analógicos do sensor USP-G41 por meio de seu conversor ADC de 12 bits. O código embarcado foi desenvolvido em C++ utilizando o *framework* PlatformIO [40]. A classificação é feita embarcando o modelo DT ou RF, previamente treinado em Python e convertido para execução local por meio de bibliotecas otimizadas.

Authorized licensed use limited to: Universidade Estadual de Campinas. Downloaded on October 04,2026 at 19:37:19 UTC from IEEE Xplore. Restrictions apply.

O sistema opera com uma taxa de amostragem de 100 Hz, realizando a leitura da janela de 100 amostras, normalização local, extração dos principais atributos estatísticos e aplicação do classificador. O resultado é exibido via interface serial e pode ser integrado a painéis de diagnóstico com comunicação MQTT ou Modbus RTU para integração industrial. Essa integração comprova a viabilidade da abordagem proposta para aplicações em tempo real, utilizando microcontroladores de baixo custo, como o ESP32, sem necessidade de infraestrutura de computação externa [50], [51].

V. Resultados e Avaliação

Para avaliar a eficácia dos modelos clássicos na tarefa de detecção de vazamentos, foi utilizada a base de atributos extraídos via TSFEL. Os dados foram padronizados com o *z-score* da biblioteca *Scikit-learn* [24] e divididos em conjuntos de treinamento (80%) e teste (20%) com estratificação.

A. Importância das Características

A primeira etapa na construção dos modelos foi identificar quais seriam as características mais relevantes para a tarefa de classificação. Para isso, foi utilizado um modelo baseado em *Random Forest*, configurado com 100 árvores de decisão (`n_estimators=100`), sem limitação explícita de profundidade máxima (permitindo que cada árvore crescesse até que todas as folhas fossem puras ou contivessem menos do que o número mínimo de amostras). O critério de impureza adotado para as divisões foi o índice de Gini (`criterion="gini"`), e o valor de `random_state=42` foi fixado para garantir a reprodutibilidade dos resultados. A seleção das 10 características mais relevantes foi feita com base na média das importâncias atribuídas por todas as árvores da floresta. A Figura 4 ilustra as 10 características mais relevantes para o modelo, dentre as quais se destacam:

- **MFCC 2, 3 e 4**: coeficientes cepstrais derivados da transformada de Fourier, comumente usados em análise de sinais de voz, mas aqui adaptados para capturar padrões dinâmicos do sinal de pressão.
- ***Negative turning points***: contagem de pontos de inversão negativa na série temporal, indicando oscilações e instabilidades.
- ***Entropy***: mede a imprevisibilidade do sinal, relevante para identificar padrões ruidosos associados a vazamentos.
- ***Kurtosis*, Max, *ECDF Percentile***: estatísticas clássicas que capturam dispersão, extremos e distribuição cumulativa.

Neste trabalho, optou-se pela utilização da técnica de *feature importance* baseada em *Random Forest* para a seleção dos atributos mais relevantes, em vez de métodos tradicionais como filtros ou abordagens *wrapper*. Essa escolha se justifica por alguns fatores. Primeiramente, a técnica de importância de atributos fornece uma estimativa direta e interpretável da influência de cada variável no processo decisório do modelo, permitindo uma compreensão mais clara do comportamento interno da classificação. Além disso, métodos *wrapper* exigem múltiplas execuções de modelos durante a busca por combinações ideais de atributos, o que implica em maior custo computacional — fator crítico em aplicações embarcadas com recursos limitados. Por outro lado, a *feature*

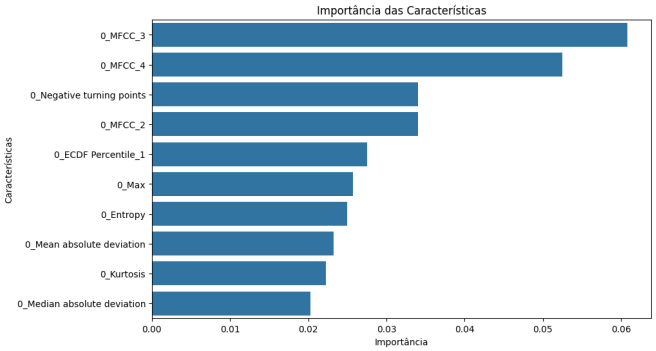


Fig. 4. Importância das Características segundo o modelo *Random Forest*.

importance extraída de modelos baseados em árvores, como a *Random Forest*, combina robustez a ruídos, eficiência computacional e independência do modelo preditivo final, permitindo que os atributos selecionados sejam aproveitados por diferentes classificadores com consistência. A literatura reforça que, embora ambas as abordagens tenham propósitos relacionados, a análise de importância dos atributos oferece maior transparência ao explicar o modelo treinado, sendo especialmente útil em contextos industriais sensíveis à interpretabilidade e à rastreabilidade das decisões automatizadas [52].

B. Modelos Supervisionados

Os cinco modelos considerados foram os seguintes:

- ***Decision Tree* (DT):** O modelo foi implementado com `sklearn.tree.DecisionTreeClassifier`, utilizando os parâmetros padrão. Embora seja uma abordagem simples, destaca-se por sua alta interpretabilidade e viabilidade de embarque. Seus resultados servem como referência (*baseline*) para comparação com modelos mais complexos.
- ***Random Forest* (RF):** O modelo foi implementado com `sklearn.ensemble.RandomForestClassifier`, utilizando 100 estimadores (`n_estimators=100`) e semente aleatória igual a 42. A utilização de múltiplas árvores de decisão em conjunto melhora a generalização e reduz o risco de *overfitting* típico de classificadores baseados em árvores isoladas [26].
- ***Multi-Layer Perceptron* (MLP):** O modelo MLP foi implementado com o `sklearn.neural_network.MLPClassifier`, configurado com uma camada oculta de 100 neurônios (`hidden_layer_sizes=(100,)`) e limite de 300 épocas de treinamento. Utiliza *backpropagation* com o otimizador `Adam`. Embora apresente maior custo computacional em comparação com modelos como ELM, o MLP é compatível com *frameworks* como TensorFlow Lite, o que permite sua implantação em sistemas embarcados.
- ***Extreme Learning Machine* (ELM)**: O modelo ELM foi implementado por meio da biblioteca `hpelm`, utilizando 200 neurônios na camada oculta e função de ativação tangente hiperbólica. Esse modelo se destaca

Authorized licensed use limited to: Universidade Estadual de Campinas. Downloaded on October 04,2026 at 19:37:19 UTC from IEEE Xplore. Restrictions apply.

pela alta velocidade de treinamento, uma vez que dispensa o uso de *backpropagation*, calculando diretamente a pseudoinversa da matriz de ativações [25]. No entanto, sua implementação embarcada ainda exige a conversão dos pesos para C/C++ a fim de viabilizar a inferência em tempo real em dispositivos com recursos computacionais restritos

- ***Echo State Network* (ESN)**: O modelo ESN foi implementado com 200 unidades no reservatório, conectividade esparsa de 10% e *leaking rate* de 0.3. Para este trabalho, foi desenvolvida uma classe personalizada da ESN, com base na abordagem descrita em [31]. A principal vantagem das redes ESN está na capacidade de modelar dependências temporais complexas por meio de um treinamento eficiente, que ajusta apenas a camada de saída, mantendo o reservatório fixo [29], [31]. Além disso, sua estrutura baseada em *buffer* circular torna o modelo especialmente atrativo para aplicações embarcadas e inferência em tempo real.

VI. Resultados e Avaliação

Para avaliar a eficácia dos modelos na tarefa de detecção de vazamentos, foi utilizada a base de atributos extraídos via TSFEL. Os dados foram padronizados com `sklearn.preprocessing.StandardScaler` e divididos em conjuntos de treinamento (80%) e teste (20%) com estratificação.

Os rótulos das classes foram codificados seguindo a seguinte convenção:

- Classe '0': Operação normal no avanço do atuador;
- Classe '1': Operação normal no recuo do atuador;
- Classe '2': Vazamento durante o avanço;
- Classe '3': Vazamento durante o recuo.

Os resultados obtidos com todos os modelos, em termos da acurácia [30] e tempos médios de inferência por amostra, são apresentados na Tabela II.As simulações foram realizadas em um notebook com processador Intel Core i5-1135G7 de 11ª geração (2.40GHz), 8 GB de RAM, sistema operacional Windows 64 bits e Python 3.10, sem uso de aceleração por GPU.

TABLE II
Desempenho dos modelos na classificação de vazamentos

Modelo	Acurácia	Inferência (ms)	Embarcável?
DT	96.0%	0.004	Alta, simples
RF	100.0%	0.070	Parcial, RAM alta
MLP	100.0%	0.036	Sim, via TFLite
ELM	100.0%	0.069	Sim, leve direto
ESN	98.4%	0.070	Possível, otimização

A Tabela II apresenta os resultados de acurácia e tempo médio de inferência, além de uma análise qualitativa da viabilidade de implementação embarcada dos modelos. Observa-se que, entre os modelos de redes neurais artificiais, tanto o ELM quanto a MLP são viáveis para embarque. A ELM se destaca por sua arquitetura extremamente simples — com camada oculta de pesos fixos e saída linear — permitindo implementação direta em C/C++ sem dependência de bibliotecas específicas. A MLP, embora apresente desempenho semelhante, requer o uso de bibliotecas otimizadas como o *TensorFlow Lite* para microcontroladores.

A *Random Forest*, apesar da acurácia perfeita, exige grande volume de memória para armazenar múltiplas árvores, o que pode limitar seu uso embarcado. A *Decision Tree* (DT) é totalmente embarcável e extremamente leve, mas apresentou ligeira queda de desempenho. A ESN mostrou-se promissora, mas sua complexidade estrutural e dependência do reservatório limitam sua implementação nesta etapa do projeto. Portanto, o ELM representa uma solução de equilíbrio ideal entre robustez preditiva e simplicidade computacional para manutenção preditiva embarcada.

A Figura 5 mostra que o modelo Decision Tree (DT) apresentou confusão entre classes normais e com vazamento, reduzindo sua acurácia para 96%, embora permaneça adequado para aplicações com baixo custo computacional.

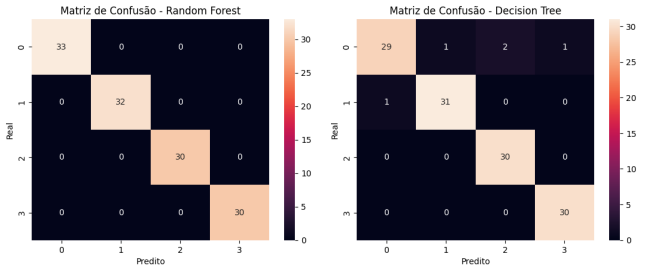


Fig. 5. Matrizes de confusão para os modelos RF (esquerda) e DT (direita).

Já RF e ELM foram altamente discriminativos, com desempenho similar ao da MLP, como mostra a Figura 6, evidenciando a eficiência de modelos sem retropropagação para aplicações com restrições de recursos.

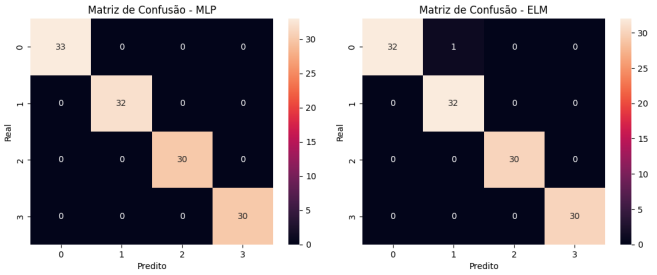


Fig. 6. Matrizes de confusão para os modelos MLP (esquerda) e ELM (direita).

Apesar da boa performance da Echo State Network (ESN), observada na Figura 7 (98.4%), optou-se por não embarcá-la nesta fase devido à complexidade de implementação do reservatório em microcontroladores.

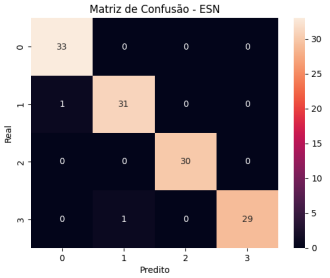


Fig. 7. Matriz de confusão do modelo ESN.

Authorized licensed use limited to: Universidade Estadual de Campinas. Downloaded on October 04,2026 at 19:37:19 UTC from IEEE Xplore. Restrictions apply.

Entre os modelos, apenas o ELM foi efetivamente implementado no ESP32. Sua arquitetura relativamente simples — com camada oculta de pesos fixos e saída treinada via pseudoinversa — permite exportação direta dos pesos para código C/C++, possibilitando inferência em tempo real com consumo mínimo de recursos.

Embora o MLP tenha apresentado tempo médio de inferência ligeiramente inferior ao ELM, sua implantação em microcontroladores requer frameworks especializados, como TensorFlow Lite, o que aumenta a complexidade do processo e a dependência de recursos adicionais. Já o ELM, por dispensar retropropagação na fase de treinamento e utilizar pesos fixos na camada oculta, permite exportação direta para código embarcado, garantindo maior controle sobre o uso de memória e latência em ambientes industriais com recursos limitados.

O protótipo final, mostrado na Figura 8, executa leitura, normalização, extração de atributos e classificação em tempo real no ESP32, com saídas visual (LED), sonora (*buzzer*) e serial, validando a proposta de um sistema robusto, embarcável e de baixo custo para manutenção preditiva. No sistema implementado, o ESP32 utilizou seus dois núcleos: um dedicado ao pré-processamento dos sinais e outro à classificação com o modelo ELM. Embora o tempo total de inferência não tenha sido medido isoladamente, o sistema operou de forma responsiva em tempo real durante os testes práticos.

VII. Conclusão

Este artigo evidenciou que a combinação entre sensores de pressão, a biblioteca TSFEL e modelos clássicos de aprendizado de máquina constitui uma solução viável, robusta e de baixo custo para a detecção de vazamentos em sistemas eletropneumáticos. Entre os modelos avaliados, o Extreme Learning Machine (ELM) destacou-se por sua compatibilidade com sistemas embarcados, tendo sido implementado com sucesso no ESP32, operando em tempo real com baixo consumo de recursos. A proposta demonstrou resiliência frente a ambientes industriais ruidosos, uma vez que se baseia exclusivamente em sinais internos do sistema, superando limitações de técnicas acústicas e visuais. Como perspectivas futuras, pretende-se expandir os testes em cenários industriais reais, explorar modelos ainda mais leves e incorporar técnicas de interpretabilidade para aumentar a rastreabilidade e a confiabilidade das decisões automatizadas em aplicações embarcadas.

References

[1] ISO 8573-1:2010, "Compressed Air—Part 1: Contaminants and Purity Classes," International Organization for Standardization, 2010.

[2] Carvalho, L. F., Souza, R. M., and Pacheco, A. G., "Data-driven approach for pneumatic fault detection using machine learning and feature extraction," *IEEE Latin America Transactions*, vol. 18, no. 09, pp. 1574–1581, Sep. 2020.

[3] FESTO. *Safety engineering guidelines Pneumatic and electric solutions*. 2011. Disponível em: FESTO Safety Guidelines.

[4] Baumann, C., *How predictive maintenance best practices can achieve electrical safety*. Disponível em: Article on Electrical Safety Practices.

[5] Alvarez-Alvarado, M. S. et al., *Power System Reliability and Maintenance Evolution: A Critical Review and Future Perspectives*, in IEEE Access, vol. 10, pp.51922-51950, 2022. DOI: 10.1109/ACCESS.2022.3172697.

[6] Labib, A., *Computerised Maintenance Management Systems. In: Complex System Maintenance Handbook*, Springer Series in Reliability Engineering, Springer, London, 2008.

[7] Teixeira, H. N., Lopes, I., Braga, A. C., *Condition-based maintenance implementation: a literature review*, Procedia Manufacturing, v.51, pp.228-235, ISSN 2351-9789, 2020. https://doi.org/10.1016/j.promfg.2020.10.036.

[8] Sunderam, V., Mrozek, D., Molęda, M., Małysiak-Mrozek, B., Ding, W., *From Corrective to Predictive Maintenance—A Review of Maintenance Approaches for the Power Industry*. Sensors, v.23, pp.5970, 2023. Disponível em: https://doi.org/10.3390/s23135970.

[9] Bonacorso, N. G., Noll V., *Automação Eletropneumática* 12ª ed. Editora Érica. 2018.

[10] Costa, S., Silva, F.J.G., Campilho, R.D.S.G., Pereira, T., *Guidelines for Machine Tool Sensing and Smart Manufacturing Integration*, Procedia Manufacturing, v.51, pp.251-257, ISSN 2351-9789, 2020. Disponível em: https://doi.org/10.1016/j.promfg.2020.10.036.

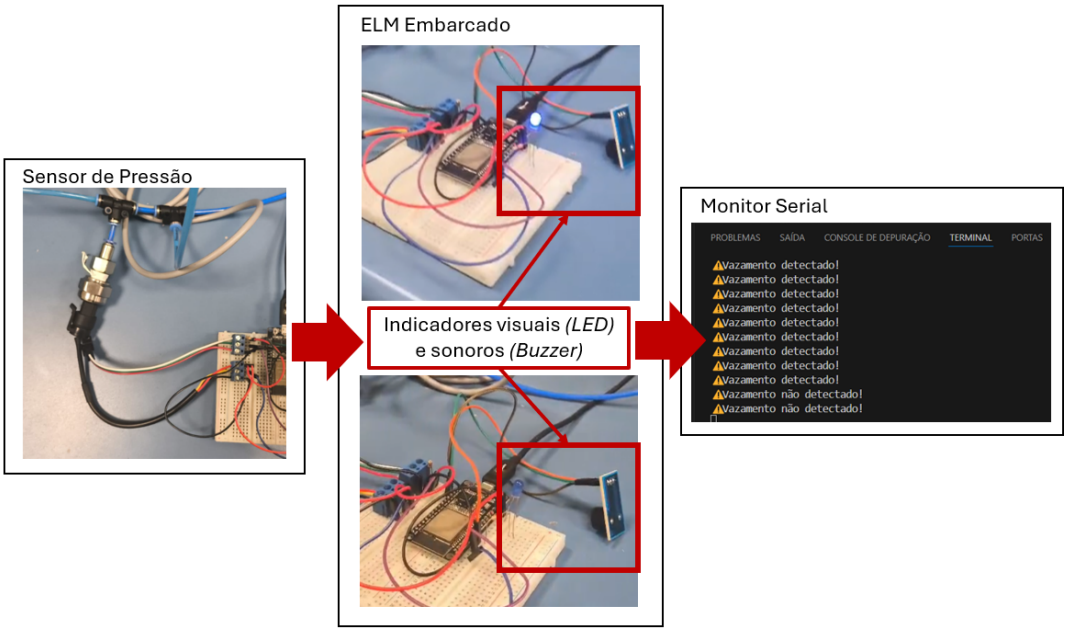


Fig. 8. Protótipo funcional com ESP32 operando em tempo real o modelo ELM embarcado. O sistema realiza leitura do sensor de pressão, extração de atributos e classificação local, com acionamento visual com o LED, sonoro com o *buzzer* e exibição de alertas no monitor serial.

Authorized licensed use limited to: Universidade Estadual de Campinas. Downloaded on October 04,2026 at 19:37:19 UTC from IEEE Xplore. Restrictions apply.

[11] Corciova, C., Andriţoi, D., Luca, C., *A Modern Approach for Maintenance Prioritization of Medical Equipment*, IntechOpen, 2021.

[12] Lee, S.M., Lee, D., Kim, Y.S., *The quality management ecosystem for predictive maintenance in the Industry 4.0 era*. Int J Qual Innov 5, Springer Nature, 2019. Disponível em: https://doi.org/10.1186/s40887-019-0029-5.

[13] Foit, K., Banaś, W., Ćwikła, G., *The pneumatic and electropneumatic systems in the context of 4th industrial revolution*, IOP Conference Series: Materials Science and Engineering, ModTech, 2018.

[14] Wang, J., Wang, Q., *Intelligent explicit model predictive control based on machine learning for microbial desalination cells*, SAGE Publishing, 2018. Disponível em: https://doi.org/10.1177/0959651818816845.

[15] Assim, M., Obeidat, Q., Hammad, M., *Software Defects Prediction using Machine Learning Algorithms*, 2020 International Conference on Data Analytics for Business and Industry: Way Towards a Sustainable Economy (ICDABI), Sakheer, Bahrain, pp. 1-6, 2020.

[16] Verma, N. K., Sevakula, R. K., Dixit, S., Salour, A., *Intelligent Condition Based Monitoring using Acoustic Signals for Air Compressors*, IEEE Transactions on Reliability, v.65, pp.291-309, 2016.

[17] Sano, H., Malere, J., Berton, L, *Single and Multiple Failures Diagnostics of Pneumatic Valves using Machine Learning*, Anais do XVI Encontro Nacional de Inteligência Artificial e Computacional, pp.202-213, Porto Alegre: SBC, 2019.

[18] Kovacs, T., Ko, A., *Monitoring Pneumatic Actuators Behavior Using Real-World Data Set*. SN COMPUT. SCI. 1, v.196, 2020. Disponível em: https://doi.org/10.1007/s42979-020-00202-2.

[19] Britzger, M., Beckmann, N., *Machine Learning Models Predict Compressed Air Anomalies*. Emerson Automation Solutions. 2022. Disponível em: Emerson Automation Solutions.

[20] Ribeiro, E., Silva, A., and Oliveira, T., "Artificial Intelligence applied to predictive maintenance of compressed air systems," in *Proc. 2019 IEEE Int. Conf. on Industrial Technology (ICIT)*, Melbourne, 2019, pp. 634–639.

[21] Verstraete, D., Ferrada, P., Droguett, E., Meruane, V., and Modarres, M., "Deep learning enabled fault diagnosis using time-frequency image analysis of rolling element bearings," *Shock and Vibration*, vol. 2017.

[22] Zhang, Y., Wang, S., and Ji, G., "A comprehensive survey on particle swarm optimization algorithm and its applications," *Neural Computing and Applications*, vol. 27, pp. 319–339, 2018.

[23] Barandas, M., Folgado, D., Fernandes, L., Santos, S., Abreu, M., Bota, P., Liu, H., Schultz, T., and Gamboa, H., "TSFEL: Time Series Feature Extraction Library," *SoftwareX*, vol. 11, 2020.

[24] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., *et al.* (2011). "Scikit-learn: Machine Learning in Python". *Journal of Machine Learning Research*, 12, 2825–2830.

[25] Huang, G.-B., Zhu, Q.-Y., and Siew, C.-K., "Extreme learning machine: theory and applications," *Neurocomputing*, vol. 70, pp. 489–501, 2006.

[26] Breiman, L., "Random forests," *Machine learning*, vol. 45, no. 1, pp. 5–32, 2001.

[27] Lukosevicius, M., and Jaeger, H., "Reservoir computing approaches to recurrent neural network training," *Computer Science Review*, vol. 3, no. 3, pp. 127–149, 2009.

[28] Yarowsky, D., "Unsupervised word sense disambiguation rivaling supervised methods," in *33rd Annual Meeting of the Association for Computational Linguistics*, 1995.

[29] Lukosevicius, M., and Jaeger, H., "Reservoir computing approaches to recurrent neural network training," *Computer Science Review*, vol. 3, no. 3, pp. 127–149, 2009.

[30] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed., Springer, 2009. [Online]. Disponível em: https://link.springer.com/book/10.1007/978-0-387-84858-7

[31] Boccato, L., "Análise de redes recorrentes e seus reservatórios para tarefas de processamento de sinais," Tese de Doutorado, Universidade Estadual de Campinas (UNICAMP), Faculdade de Engenharia Elétrica e de Computação, Campinas, SP, 2013. Orientador: Romis Ribeiro de Faissol Attux.

[32] Brownlee, G., "Machine Learning Mastery with Python". Machine Learning Mastery," 2016. Disponível em: https://www.machinelearningmastery.com/machine-learning-with-python/.

[33] Mahdi, N., Hikmet, A., Abulqasim, S., Basem, A., Ogaili, A., Al-Haddad, L., "Leak Detection and Localization in Water Distribution Systems Using Advanced Feature Analysis and An Artificial Neural Network", Desalination and Water Treatment, 320, 100685, 2024.https://doi.org/10.1016/j.dwt.2024.100685.

[34] Ma, X., Xu, H., Ju, C. "Class-specific feature selection via maximal dynamic correlation change and minimal redundancy," Expert Syst. Appl. 229, PA, 2023. https://doi.org/10.1016/j.eswa.2023.120455.

[35] A. V. Turukmane and R. Devendiran, "M-MultiSVM: An efficient feature selection assisted network intrusion detection system using machine learning," *Comput. Secur.*, vol. 137, p. 103587, 2024. https://doi.org/10.1016/j.cose.2023.103587.

[36] Z. Wang et al., "A lightweight IoT intrusion detection model based on improved BERT-of-Theseus," *Expert Syst. Appl.*, vol. 238, p. 122045, 2023. https://doi.org/10.1016/j.eswa.2023.122045.

[37] L. Thodupunuri, N. Peesari and S. Utukuru, "Interpretable Anomaly Detection in Industrial Control Systems Using Federated Learning," 2024 8th International Conference on Inventive Systems and Control (ICISC), Coimbatore, India, 2024, pp. 687-692, https://doi.org/10.1109/ICISC62624.2024.00122.

[38] Samala, R.K., et al., "Risks of feature leakage and sample size dependencies in deep feature extraction for breast mass classification, " Med. Phys., 48: 2827-2837, 2021.https://doi.org/10.1002/mp.14678.

[39] Nfissi, A., Bouachir, W., Bouguila, N. et al. "Unveiling hidden factors: explainable AI for feature boosting in speech emotion recognition, " Appl Intell 54, 7046–7069, 2024. https://doi.org/10.1007/s10489-024-05536-5

[40] PlatformIO, "What is PlatformIO?" *PlatformIO Documentation*, 2024. https://docs.platformio.org/en/latest/what-is-platformio.html.

[41] Sivaramakrishnan, R., SenthilKumar, G., "Workload Characterization in Embedded Systems Utilizing Hybrid Intelligent Gated Recurrent Unit and Extreme Learning Machines". *International Journal of Intelligent Systems and Applications in Engineering*, 12(1s), 233–243. Disponível em: https://www.ijisae.org/index.php/IJISAE/article/view/3411

[42] Shritharanyaa, Jp, et. al., "Enhancing the performance of extreme learning machine technique using optimization algorithms for embedded workload characterization". *Alexandria Engineering Journal*. 108. 509-517. 2024 10.1016/j.aej.2024.07.100.

[43] Zhou, J., Jiang, Y., Xu, L., et al., "Echo State Network Based on Improved Knowledge Distillation for Edge Intelligence," *Chinese Journal of Electronics*, vol. 33, no. 1, pp. 101–111, 2024. DOI: 10.23919/cje.2022.00.292

[44] Jafari, A., Platzner, M., "Ultra-Low Latency and Extreme-Throughput Echo State Neural Networks on FPGA" In: Giorgi, R., Stojilović, M., Stroobandt, D., Brox Jiménez, P., Barriga Barros, Á. (eds) Applied Reconfigurable Computing. Architectures, Tools, and Applications. ARC 2025. Lecture Notes in Computer Science, vol 15594. Springer, Cham.. DOI: https://doi.org/10.1007/978-3-031-87995-1_11

[45] Chen, K. H., Huang, Y. J., Wang, P. H., "Efficient Realization of Decision Trees for Real-Time Inference," *ACM Transactions on Embedded Computing Systems*, vol. 21, no. 3, pp. 1–24, 2022.

[46] Daghero, F., Monge, M. F., Blok, M., "Adaptive Random Forests for Energy-Efficient Inference on Microcontrollers," *arXiv preprint arXiv:2205.13838*, 2022.

[47] Ling, T., Memon, M. A., Peng, X., "Configurable Multi-Layer Perceptron-Based Soft Sensors on Embedded Field Programmable Gate Arrays: Targeting Diverse Deployment Goals in Fluid Flow Estimation," *Sensors*, vol. 25, no. 1, p. 83, 2025.

[48] El-Bakry, A. M., Mousa, M. H., Ismail, M. I., "Enhancing the Performance of Extreme Learning Machine Technique for Embedded Workload Characterization," *Alexandria Engineering Journal*, vol. 63, pp. 1–10, 2024.

[49] Alzubaidi, M. A., Qaisar, S., "Delay Embedded Echo-State Network: A Predictor for Partially Observed Systems," *IFAC-PapersOnLine*, vol. 56, no. 2, pp. 1234–1240, 2023.

[50] Aghenta, L. O., Iqbal, M. T., "Design and implementation of a low-cost, open source IoT-based SCADA system using ESP32 with OLED, ThingsBoard and MQTT protocol," *AIMS Electronics and Electrical Engineering*, vol. 4, no. 1, pp. 57–86, 2020. DOI: https://doi.org/10.3934/ElectrEng.2020.1.57

[51] PickData, "eCore - ESP32 IoT Controllers for Industrial Use - Mini PLC," 2024. Disponível em: https://www.pickdata.net/ecore-esp32-iot-controllers-industrial-mini-plc. Acessado em: 15 mai. 2025.

[52] Kaur, H., Kaur, R., Bhatia, M.S., "Feature selection and extraction using machine learning techniques: A review," *SN Applied Sciences*, vol. 3, no. 7, pp. 1–20, 2021.

Authorized licensed use limited to: Universidade Estadual de Campinas. Downloaded on October 04,2026 at 19:37:19 UTC from IEEE Xplore. Restrictions apply.