Pós Graduação
Data Science e Big Data na Indústria

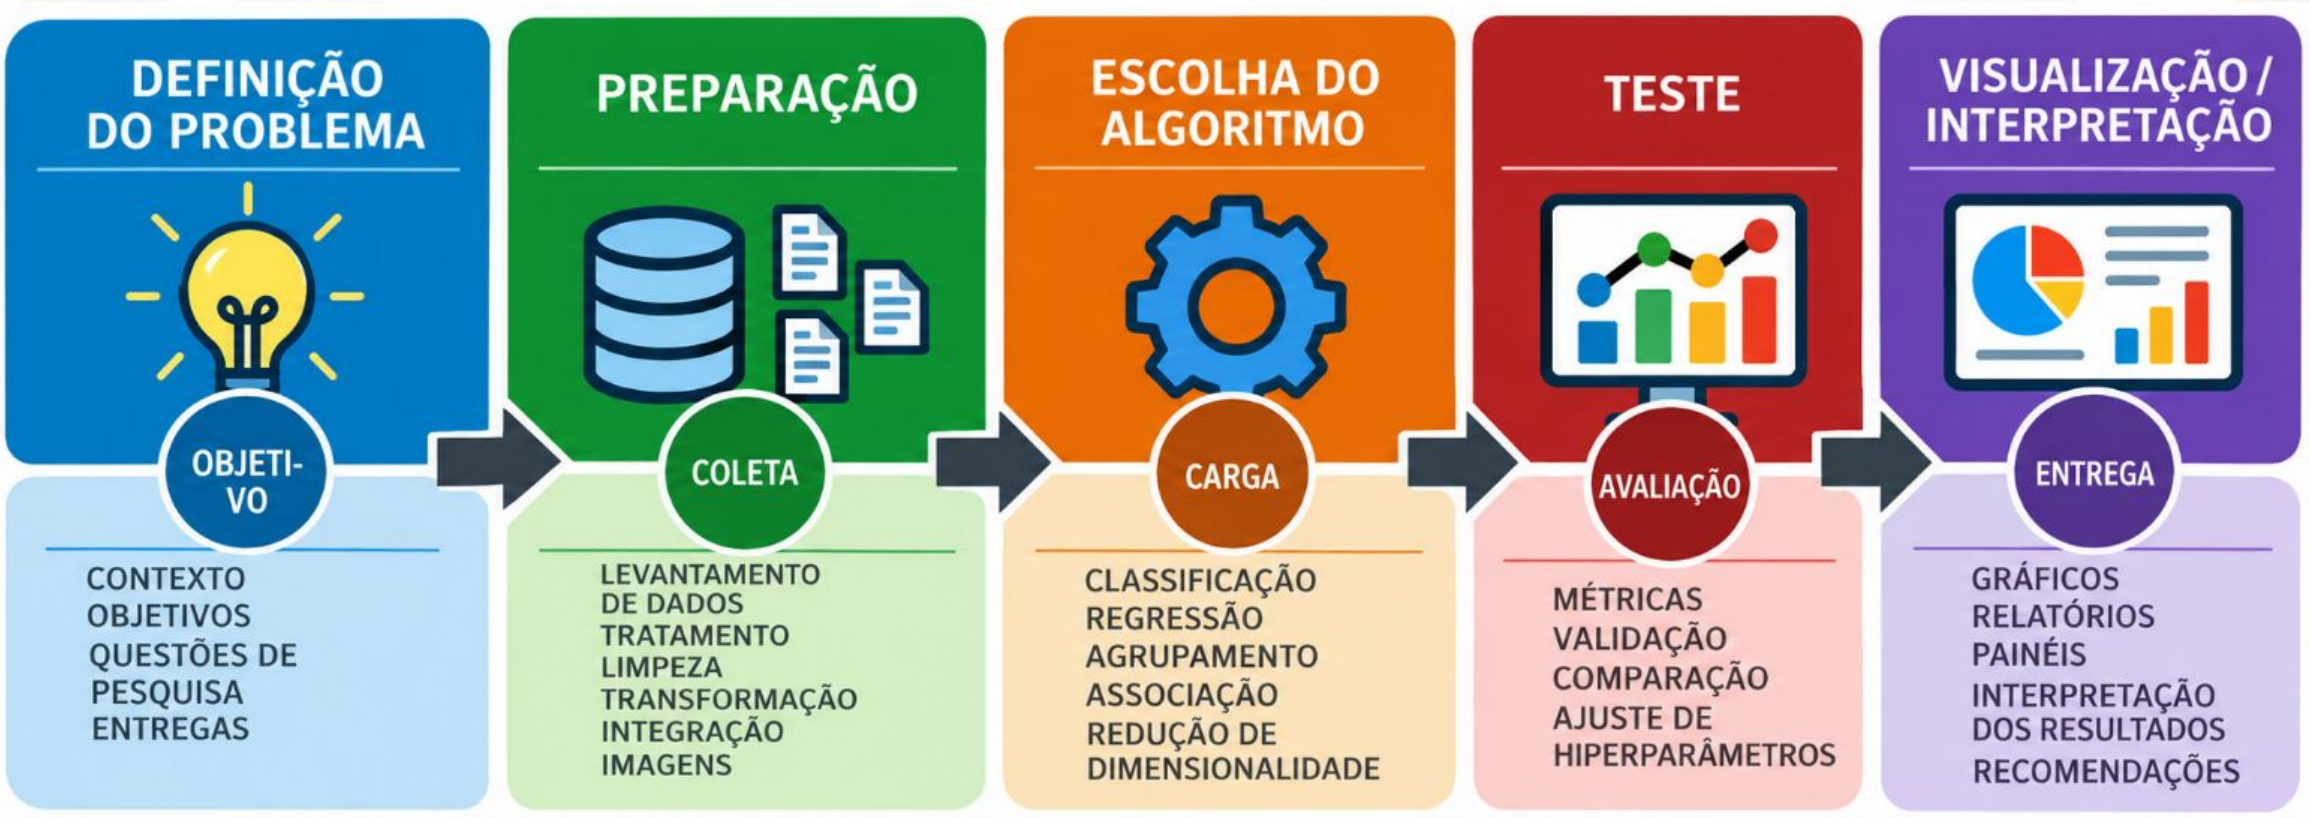
Disciplina: Data Science e Big Data

Aula 02

Prof. Me Daniel Vieira

UNISENAI
Inovação no Ensino Superior para a Indústria

Etapas de um projeto de Data Science



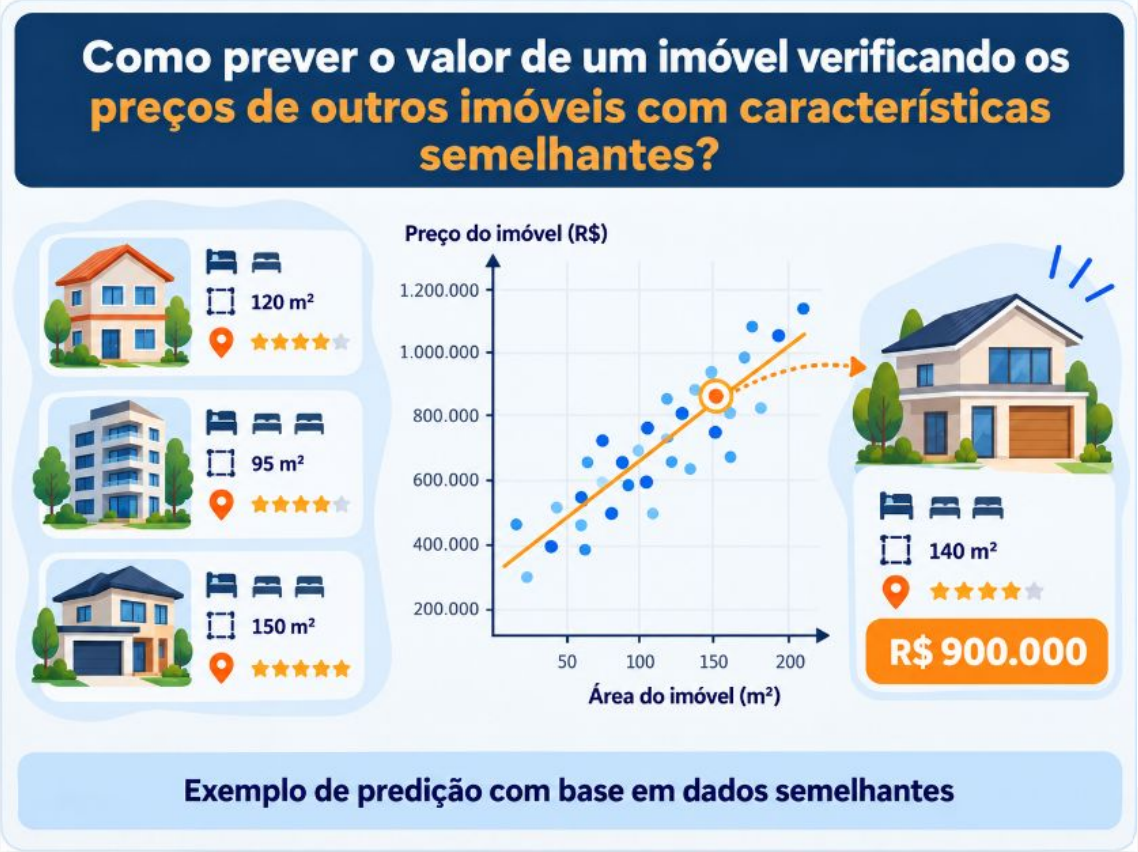
Exemplos de problemas





Exemplos de problemas





UNISENAI Inovação no Ensino Superior para a Indústria

Exemplos de problemas

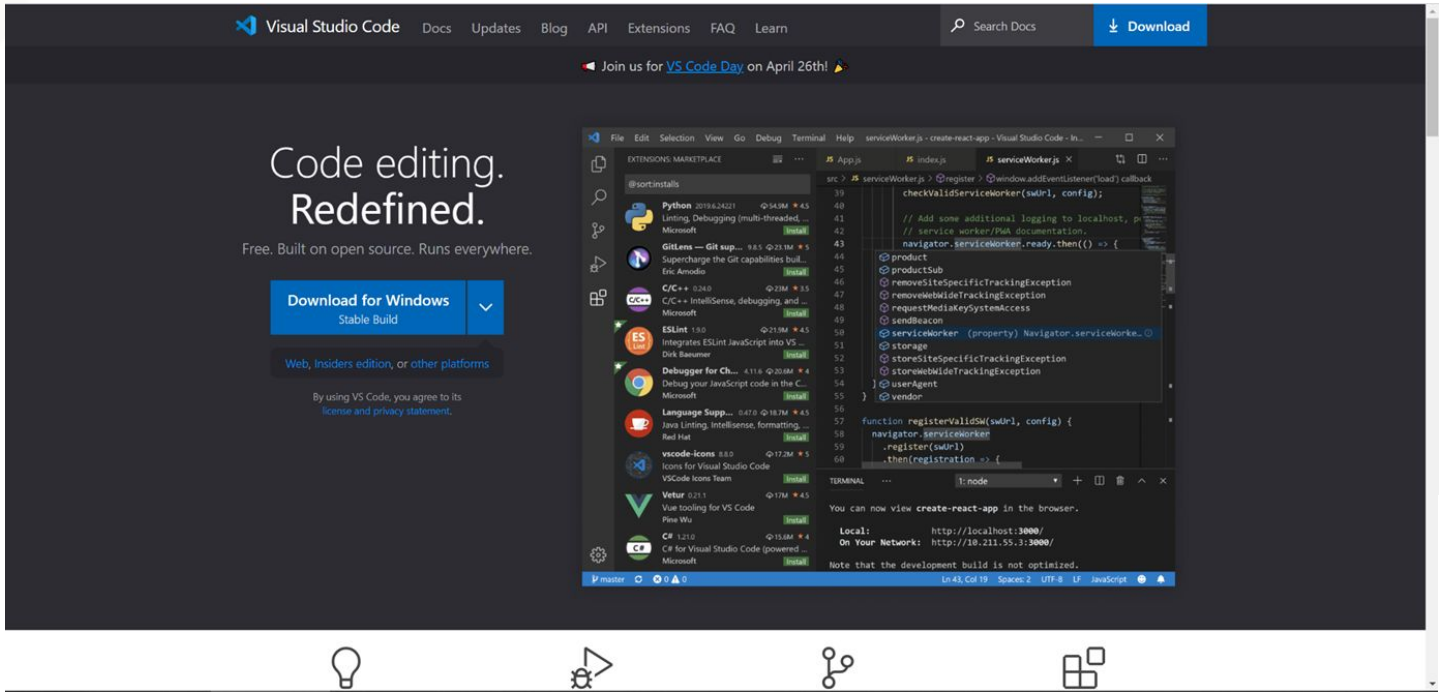




Exemplos de problemas



Recursos utilizados para Data Science

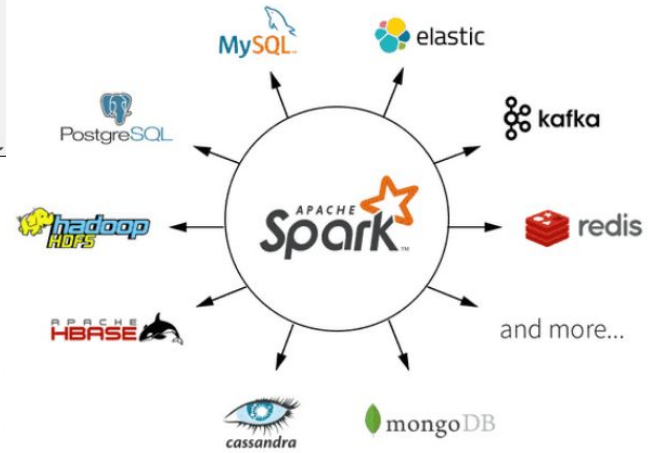












UNISENAI Inovação no Ensino Superior para a Indústria

Biblioteca Pandas

A biblioteca Pandas é uma biblioteca responsável por realizar a leitura de arquivos externos no formato csv, xlsx, parquet.



Biblioteca Pandas

Limpeza, tratamento de dados, análise exploratória dos dados, suporte em atividades de Machine Learning, consultas, queries em bancos de dados, visualização de dados, web scraping e etc

Biblioteca Pandas

Séries e Dataframes

As séries são arrays unidimensionais e com um eixo de rótulos chamado index

```
0      1.4
1      1.4
2      1.3
3      1.5
4      1.4
      ...
145    5.2
146    5.0
147    5.2
148    5.4
149    5.1
```

Biblioteca Pandas

Dataframes - são objetos bidimensionais de tamanho variável. Formato de tabela

produto	producao	defeitos	temperatura
Motor A	100	5	70
Motor B	120	12	82
Motor A	110	6	73
Motor C	90	3	68
Motor B	130	15	85

Biblioteca Pandas - Instalação

pip install pandas

Caso não tenha o pacote pip instalado na máquina instalar o pacote pip

python -m ensurepip –upgrade

```
# importando a biblioteca pandas
import pandas as pd
```

Biblioteca Pandas - Principais funções

Comando	Para que serve
`pd.DataFrame()`	Cria um DataFrame
`pd.read_csv()`	Lê arquivo CSV
`pd.read_excel()`	Lê arquivo Excel
`df.head()`	Mostra as primeiras linhas
`df.tail()`	Mostra as últimas linhas
`df.shape`	Mostra quantidade de linhas e colunas

Biblioteca Pandas - Principais funções

`df.columns`	Mostra os nomes das colunas
`df.info()`	Mostra tipos de dados e valores nulos
`df.describe()`	Estatísticas descritivas
`df["coluna"]`	Seleciona uma coluna
`df[["col1","col2"]]`	Seleciona várias colunas
`df.loc[]`	Seleção por rótulo/condição
`df.iloc[]`	Seleção por posição

Biblioteca Pandas - Principais funções

`df.query()`	Filtra usando expressão
`df.sort_values()`	Ordena os dados
`df.groupby()`	Agrupa os dados
`df.value_counts()`	Conta ocorrências
`df.mean()`	Calcula média
`df.sum()`	Calcula soma
`df.min()`	Retorna mínimo
`df.max()`	Retorna máximo

Biblioteca Pandas - Principais funções

`df.median()`	Calcula mediana
`df.std()`	Calcula desvio padrão
`df.isnull()`	Verifica valores nulos
`df.dropna()`	Remove valores nulos
`df.fillna()`	Preenche valores nulos
`df.drop()`	Remove linhas ou colunas
`df.rename()`	Renomeia colunas
`df.astype()`	Altera o tipo de dado
`df["nova"] = ...`	Cria nova coluna

Biblioteca Pandas - Principais funções

`pd.concat()`	Junta DataFrames
`pd.merge()`	Faz junção entre tabelas
`df.corr()`	Calcula correlação
`df.to_csv()`	Salva em CSV
`df.to_excel()`	Salva em Excel

Onde encontrar bases de dados para projetos Data Science ?







Exemplo: Será que o aumento de defeitos está relacionado ao aumento da temperatura ?

produto	producao	defeitos	temperatura
Motor A	100	5	70
Motor B	120	12	82
Motor A	110	6	73
Motor C	90	3	68
Motor B	130	15	85

Exemplo: Será que o aumento de defeitos está relacionado ao aumento da temperatura ?

```python
import pandas as pd

dados = {
    "produto": ["Motor A", "Motor B", "Motor A", "Motor C", "Motor B"],
    "producao": [100, 120, 110, 90, 130],
    "defeitos": [5, 12, 6, 3, 15],
    "temperatura": [70, 82, 73, 68, 85]
}

df = pd.DataFrame(dados)
```

Exemplo 1

1 - Visualizar os dados

```
1 df.head()
```

	produto	producao	defeitos	temperatura
0	Motor A	100	5	70
1	Motor B	120	12	82
2	Motor A	110	6	73
3	Motor C	90	3	68
4	Motor B	130	15	85

```
1 df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5 entries, 0 to 4
Data columns (total 4 columns):
 #   Column       Non-Null Count  Dtype
---  ------       --------------  -----
 0   produto      5 non-null      object
 1   producao     5 non-null      int64
 2   defeitos     5 non-null      int64
 3   temperatura  5 non-null      int64
dtypes: int64(3), object(1)
memory usage: 292.0+ bytes
```

Exemplo 1

1 - Visualizar os dados

```
1 df.describe()
```

	producao	defeitos	temperatura
count	5.000000	5.000000	5.000000
mean	110.000000	8.200000	75.600000
std	15.811388	5.069517	7.503333
min	90.000000	3.000000	68.000000
25%	100.000000	5.000000	70.000000
50%	110.000000	6.000000	73.000000
75%	120.000000	12.000000	82.000000
max	130.000000	15.000000	85.000000

Exemplo 1

2 - Selecionar uma coluna

```
1 df["temperatura"]
```

	temperatura
0	70
1	82
2	73
3	68
4	85

dtype: int64

Exemplo 1

2 - Selecionar várias colunas

```
1 df[["produto", "temperatura"]]
```

	produto	temperatura
0	Motor A	70
1	Motor B	82
2	Motor A	73
3	Motor C	68
4	Motor B	85

Exemplo 1

3 - Filtrar dados

```
1 df[df["temperatura"] > 75]
```

	produto	producao	defeitos	temperatura
1	Motor B	120	12	82
4	Motor B	130	15	85

Exemplo 1

3 - Filtrar dados

```
1 df[df["temperatura"] > 75]
```

	produto	producao	defeitos	temperatura
1	Motor B	120	12	82
4	Motor B	130	15	85

```
1 df[
2     (df["temperatura"] > 75) &
3     (df["defeitos"] > 10)
4 ]
```

	produto	producao	defeitos	temperatura
1	Motor B	120	12	82
4	Motor B	130	15	85

Exemplo 1

4 - Média

```
1 df["temperatura"].mean()
```

```
np.float64(75.6)
```

```
1 df["producao"].mean()
```

```
np.float64(110.0)
```

```
1 df["temperatura"].max()
```

```
85
```

```
1 df["temperatura"].min()
```

```
68
```

Exemplo 1

5 - Maior e menor valor de temperatura

```
1 df["temperatura"].max()
```

```
85
```

```
1 df["temperatura"].min()
```

```
68
```

UNISENAI
Inovação no
Ensino Superior
para a Indústria

Exemplo 1

6 - Ordenando por maior temperatura para a menor temperatura

```
df.sort_values(
    by="temperatura",
    ascending=False
)
```

	produto	producao	defeitos	temperatura
4	Motor B	130	15	85
1	Motor B	120	12	82
2	Motor A	110	6	73
0	Motor A	100	5	70
3	Motor C	90	3	68

Exemplo 1

7 - Agrupar produção média por produto

```
1 df.groupby("produto")["producao"].mean()
```

produto	producao
Motor A	105.0
Motor B	125.0
Motor C	90.0

dtype: float64

Exemplo 1

7 - Agrupar defeitos médio por produto

```
1 df.groupby("produto")["defeitos"].mean()
```

produto	defeitos
Motor A	5.5
Motor B	13.5
Motor C	3.0

dtype: float64

Exemplo 1

8 - Estatísticas

```
df.groupby("produto").agg({
    "producao": "mean",
    "defeitos": "sum",
    "temperatura": "mean"
})
```

produto	producao	defeitos	temperatura
Motor A	105.0	11	71.5
Motor B	125.0	27	83.5
Motor C	90.0	3	68.0

Exemplo 1

9 - Criando outra coluna

```
1 df["taxa_defeitos"] = (
2     df["defeitos"] / df["producao"] * 100
3 )
```

Exemplo 1

10 - Correlação

```
df[[
    "producao",
    "defeitos",
    "temperatura"
]].corr()
```

	producao	defeitos	temperatura
producao	1.000000	0.966863	0.969334
defeitos	0.966863	1.000000	0.995051
temperatura	0.969334	0.995051	1.000000

Exemplo 2- Uma indústria registra informações sobre a quantidade de peças produzidas, aprovadas e defeituosas nos turnos da manhã, tarde e noite. A gestão deseja avaliar o desempenho produtivo e a qualidade da produção. utilizam a base de dados Base de dados Dados produção

	data	turno	produto	pecas_produzidas	pecas_defeituosas	pecas_aprovadas
0	2026-01-01	Manhã	Peça metálica A	281	13	268
1	2026-01-01	Tarde	Peça metálica A	240	4	236
2	2026-01-01	Noite	Peça metálica A	297	10	287
3	2026-01-02	Manhã	Peça metálica A	335	16	319
4	2026-01-02	Tarde	Peça metálica A	296	9	287

a) Qual é a quantidade total de peças produzidas durante o período analisado?
b) Qual turno apresenta a maior produção total de peças?
c) Qual é a quantidade média de peças produzidas por registro em cada turno?
d) Qual turno apresenta o maior percentual de peças defeituosas em relação à sua produção total?

e) Existe correlação entre a quantidade de peças produzidas e a quantidade de peças defeituosas?

Código Python

```python
# Importando bibliotecas
import pandas as pd
import matplotlib.pyplot as plt

```

```python
#Importando a base de dados - arquivo csv
df=pd.read_csv('producao_por_turno_100.csv',sep=',')
```

Código Python

```
1 df.head() # Exibindo as 4 primeiras linhas da base de dados
```

	data	turno	produto	pecas_produzidas	pecas_defeituosas	pecas_aprovadas
0	2026-01-01	Manhã	Peça metálica A	281	13	268
1	2026-01-01	Tarde	Peça metálica A	240	4	236
2	2026-01-01	Noite	Peça metálica A	297	10	287
3	2026-01-02	Manhã	Peça metálica A	335	16	319
4	2026-01-02	Tarde	Peça metálica A	296	9	287

Código Python

```python
#a)Qual é a quantidade total de peças produzidas durante o período analisado?
total = df['pecas_produzidas'].sum()
print(f'A quantidade total de peças produzidas são:{total}')
```

```
A quantidade total de peças produzidas são:29479
```

```python
#b) Qual turno apresenta a maior produção total de peças?
producao_turno = df.groupby("turno")["pecas_produzidas"].sum()

print(producao_turno)
```

```
turno
Manhã    10777
Noite     8765
Tarde     9937
Name: pecas_produzidas, dtype: int64
```

Código Python

```python
print(producao_turno.idxmax()) # identifica o turno que mais produziu
```

```
Manhã
```

```python
# c. Qual é a quantidade média de peças produzidas por registro em cada turno?
media_turno = df.groupby("turno")["pecas_produzidas"].mean()

print(round(media_turno,0))
print(media_turno.idxmax())
```

```
turno
Manhã    317.0
Noite    266.0
Tarde    301.0
Name: pecas_produzidas, dtype: float64
Manhã
```

Código Python

```python
#d. Qual turno apresenta o maior percentual de peças defeituosas em relação à produção total?
defeitos_turno = df.groupby("turno").agg({
    "pecas_produzidas": "sum",
    "pecas_defeituosas": "sum"
})

print(defeitos_turno)
```

```
       pecas_produzidas  pecas_defeituosas
turno
Manhã             10777                358
Noite              8765                277
Tarde              9937                306
```

Código Python

```python
defeitos_turno["taxa_defeitos"] = (
    defeitos_turno["pecas_defeituosas"] /
    defeitos_turno["pecas_produzidas"] * 100
)

print(defeitos_turno)
```

```
        pecas_produzidas  pecas_defeituosas  taxa_defeitos
turno
Manhã              10777                358       3.321889
Noite               8765                277       3.160297
Tarde               9937                306       3.079400
```

Código Python

```python
defeitos_turno["taxa_defeitos"] = (
    defeitos_turno["pecas_defeituosas"] /
    defeitos_turno["pecas_produzidas"] * 100
)

print(defeitos_turno)
```

```
        pecas_produzidas  pecas_defeituosas  taxa_defeitos
turno
Manhã              10777                358       3.321889
Noite               8765                277       3.160297
Tarde               9937                306       3.079400
```

Código Python

```
import matplotlib.pyplot as plt
fig, ax = plt.subplots(figsize=(8, 5))
resumo["pecas_produzidas"].plot(
    kind="bar",
    ax=ax,
    color="steelblue"
)

ax.set_title("Quantidade de Peças Produzidas por Turno")
ax.set_xlabel("Turno")
ax.set_ylabel("Quantidade de Peças")
ax.tick_params(axis="x", rotation=0)

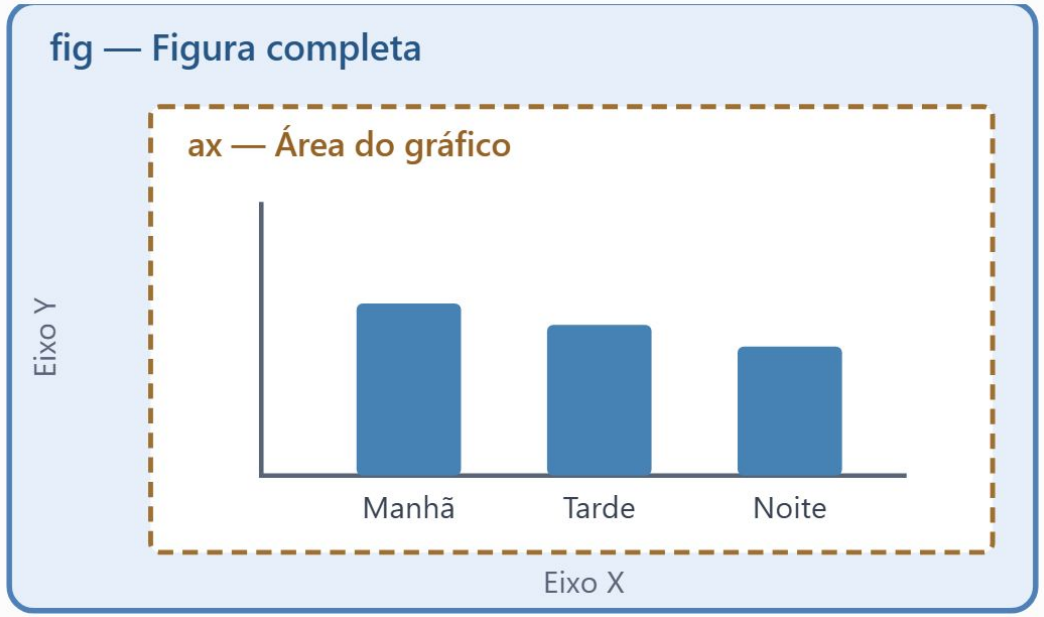
plt.tight_layout()
plt.show()

```

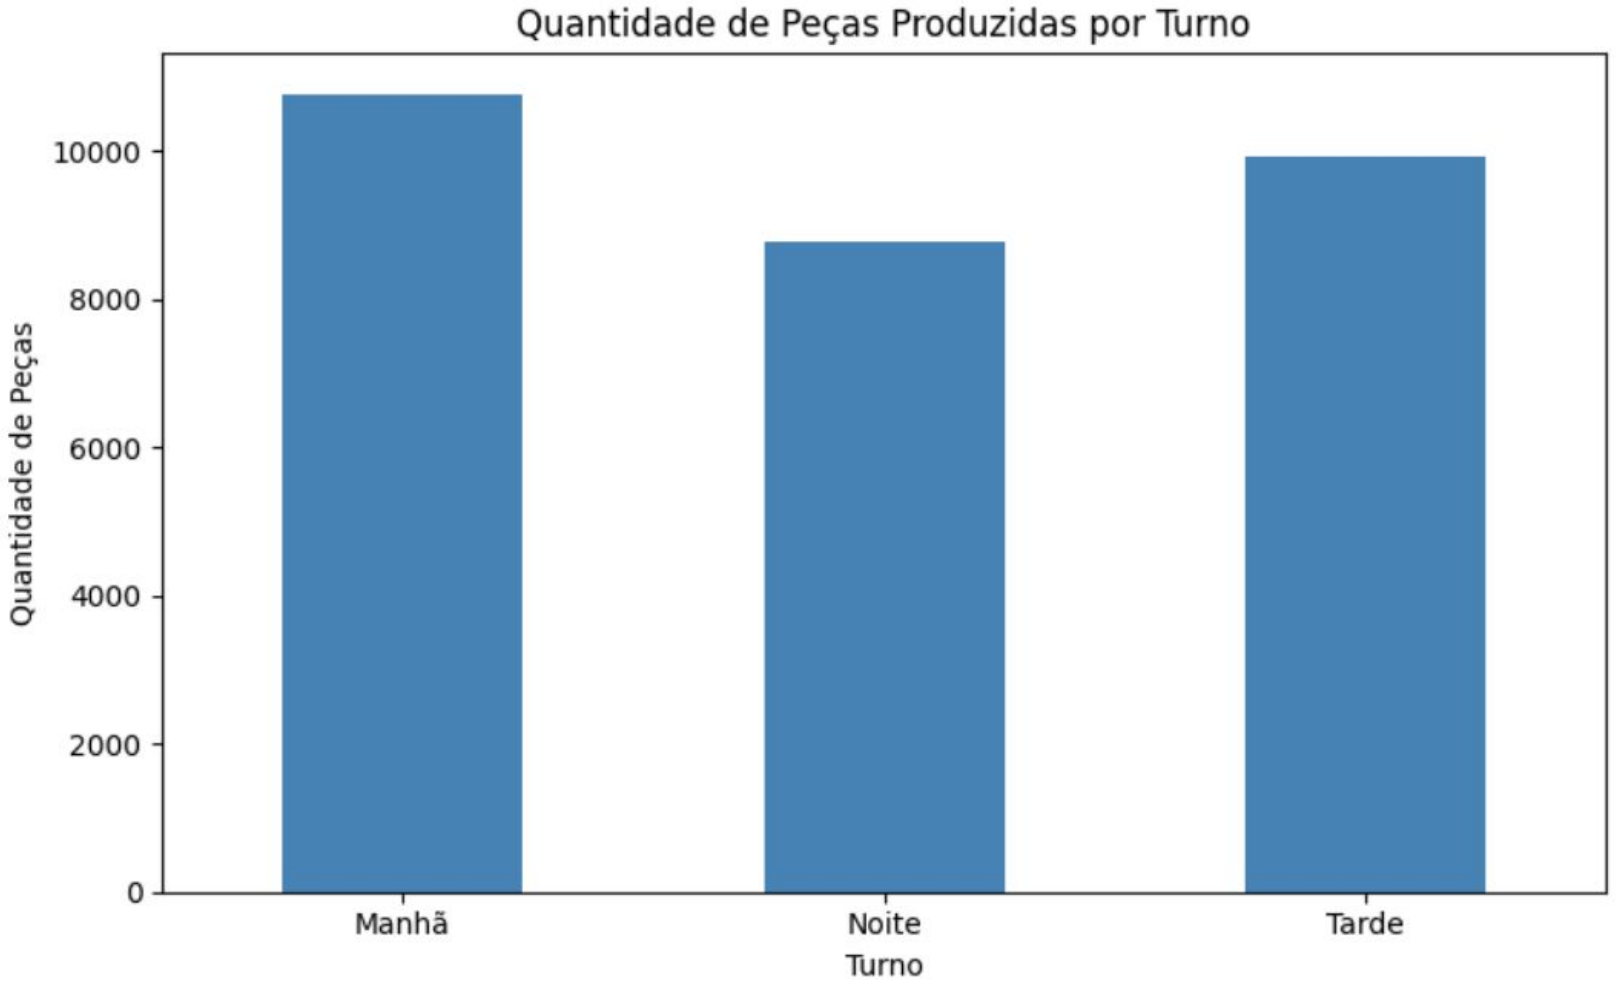
Código Python

- fig (Figure): representa a figura completa, ou seja, a área que contém o gráfico.
- ax (Axes): representa a região onde os dados serão desenhados, incluindo os eixos X e Y.

O parâmetro figsize=(8, 5) define o tamanho da figura: 8 polegadas de largura e 5 de altura.



Figura


Quantidade de Peças Produzidas por Turno
Quantidade de Peças
10000
8000
6000
4000
2000
0
Manhã
Noite
Tarde
Turno

Código Python

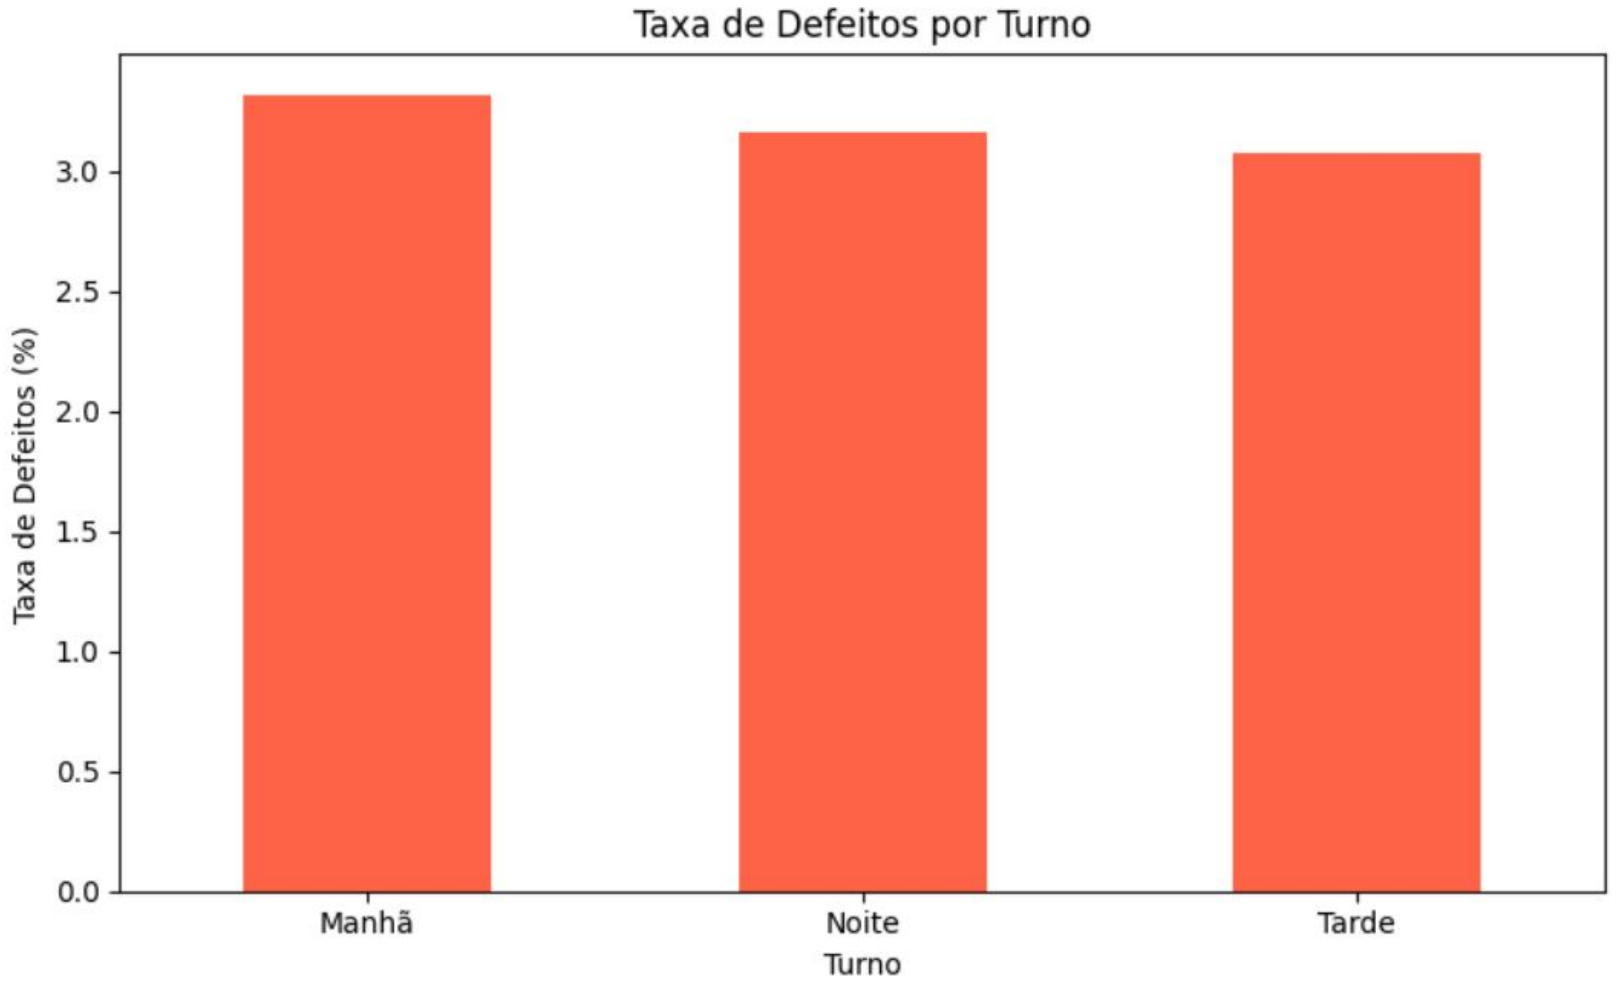
```python
fig, ax = plt.subplots(figsize=(8, 5))

resumo["taxa_defeitos"].plot(
    kind="bar",
    ax=ax,
    color="tomato"
)

ax.set_title("Taxa de Defeitos por Turno")
ax.set_xlabel("Turno")
ax.set_ylabel("Taxa de Defeitos (%)")
ax.tick_params(axis="x", rotation=0)

plt.tight_layout()
plt.show()
```

Gráfico


Taxa de Defeitos por Turno
Taxa de Defeitos (%)
0.0
0.5
1.0
1.5
2.0
2.5
3.0
Manhã
Noite
Tarde
Turno

Exercício 1 - Você tem dados de produção por máquina, consumo de energia

Máquina	Produção (peças/turno)	Energia (kWh/turno)
Máquina A	1250	420
Máquina B	1380	465
Máquina C	1190	390
Máquina D	1450	510
Máquina E	1320	405

Crie o dataframe e responda às seguintes perguntas:

a) Qual máquina produziu mais?
b) Qual máquina consome menos energia?
c) Qual foi a produção média das máquinas?
d) Qual foi o consumo médio de energia?
e)Ordene as máquinas da maior para a menor produção.
f) Crie uma nova coluna chamada eficiência, calculada por: produção/energia(KWh)
g) Qual máquina apresentou a melhor relação entre produção e consumo de energia?

Exercício 2- Uma empresa de transporte e logística acompanha diariamente a quantidade de viagens realizadas e a distância total percorrida. A gestão deseja compreender o comportamento das operações e identificar períodos de maior demanda. Base de dados Dados Viagem

	data	dia_semana	quantidade_viagens	distancia_total_km
0	2026-01-01	Quinta	45	824.0
1	2026-01-02	Sexta	32	632.7
2	2026-01-03	Sábado	21	254.8
3	2026-01-04	Domingo	31	616.9
4	2026-01-05	Segunda	37	698.9

a) Quantas viagens foram realizadas durante todo o período analisado?
b) Qual dia apresentou a maior quantidade de viagens?
c) Qual é a média diária de viagens realizadas?
d) Em qual mês foi registrada a maior quantidade total de viagens?
e) Existe correlação entre a quantidade de viagens realizadas e a distância total percorrida?

Exercício 3- Uma empresa comercializa o Produto A e mantém registros mensais de unidades vendidas, preço unitário e faturamento. A direção deseja compreender a evolução das vendas e identificar oportunidades de melhoria no desempenho comercial. Base de dados Dados Vendas

	mes	produto	unidades_vendidas	preco_unitario_rs	faturamento_rs
0	2018-01	Produto A	195	39.90	7780.50
1	2018-02	Produto A	142	40.13	5698.46
2	2018-03	Produto A	186	40.36	7506.96
3	2018-04	Produto A	188	40.59	7630.92
4	2018-05	Produto A	180	40.82	7347.60

a)Qual foi a quantidade total de unidades vendidas durante o período analisado?
b)Qual mês apresentou o maior faturamento?
c)Qual foi o faturamento total obtido com a comercialização do Produto A?
d)Qual ano apresentou a maior quantidade de unidades vendidas?
e) Existe relação entre o preço unitário do produto e a quantidade de unidades vendidas?

Notebook Google com o código e resposta das perguntas dos exercícios 1,2 e 3

Entrega das atividades através do link

Entrega da atividade

Projeto - Disciplina Data Science e Big Data

A S&M Industry é uma empresa que atua no setor de manufatura industrial, desenvolvendo soluções e componentes utilizados em processos produtivos automatizados.

Sua unidade fabril opera com equipamentos industriais responsáveis por diferentes etapas da produção. Essas máquinas funcionam continuamente, sendo monitoradas por sensores que registram informações sobre suas condições de operação.

Nos últimos meses, a empresa identificou dificuldades relacionadas a paradas não planejadas de equipamentos. Essas interrupções podem comprometer o planejamento da produção, aumentar os custos de manutenção e afetar o cumprimento dos prazos de entrega.

Atualmente, parte das decisões de manutenção é realizada de maneira corretiva, ou seja, após a identificação de um problema no funcionamento dos equipamentos.

Diante desse cenário, a direção da empresa decidiu investir em uma iniciativa de transformação digital, buscando utilizar os dados já coletados pelos sistemas industriais para apoiar decisões de manutenção.

Projeto Disciplina Data Science e Big Data

Você foi contratado como Cientista de Dados para participar desse projeto.

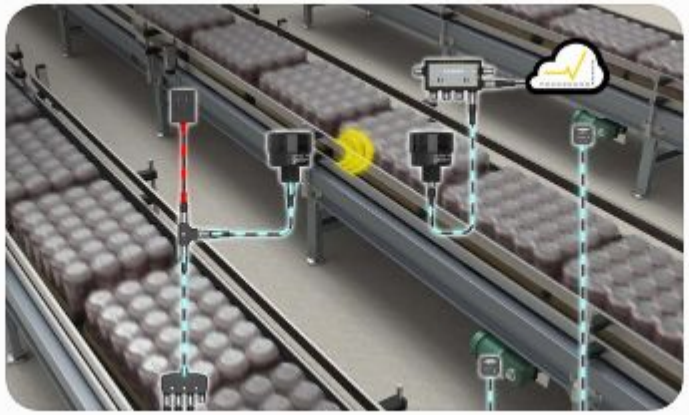
Sua missão será investigar o histórico operacional das máquinas e desenvolver análises que auxiliem a empresa a compreender quais condições estão associadas às falhas dos equipamentos.

Projeto Disciplina Data Science e Big Data

Como utilizar técnicas de Data Science, Machine Learning e Big Data para identificar padrões associados à ocorrência de falhas em equipamentos industriais e apoiar decisões de manutenção na S&M Industry Tech?

A S&M Industry possui cinco máquinas industriais monitoradas por sensores.







UNISENAI Inovação no Ensino Superior para a Indústria

Projeto Disciplina Data Science e Big Data

Os sistemas de monitoramento coletaram dados como:

Variável	Finalidade
`temperatura_c`	Identificar aquecimento excessivo
`vibracao_mm_s`	Identificar possíveis problemas mecânicos
`pressao_bar`	Monitorar condições operacionais
`corrente_a`	Identificar sobrecorrente e possíveis anomalias
`horas_operacao`	Avaliar desgaste associado ao uso
`falha`	Variável-alvo (0 = sem falha; 1 = falha)

Projeto Disciplina Data Science e Big Data

Os sistemas de monitoramento coletaram dados como:

Base de dados Dados de Manutenção

	timestamp	maquina_id	temperatura_c	vibracao_mm_s	pressao_bar	corrente_a	horas_operacao	falha
0	2026-02-05 18:00:00	M04	61.97	3.37	5.59	22.48	10154.0	0
1	2026-01-22 13:00:00	M01	60.86	2.07	6.55	23.21	2687.0	0
2	2026-01-17 05:00:00	M03	70.35	2.75	6.21	26.36	11779.0	0
3	2026-01-19 16:00:00	M02	68.22	3.55	7.23	28.03	4519.0	0
4	2026-02-07 21:00:00	M01	73.89	2.64	5.89	25.73	9899.0	0

Projeto Disciplina Data Science e Big Data

Apesar da disponibilidade desses dados, a empresa ainda não sabe como utilizá-los para responder a perguntas importantes sobre a confiabilidade dos equipamentos.

A direção deseja investigar:

- Quais condições operacionais estão associadas à ocorrência de falhas?
- Existem diferenças relevantes entre os equipamentos?

Projeto Disciplina Data Science e Big Data

- É possível identificar padrões nos registros utilizando técnicas de mineração de dados?
- Algoritmos de Machine Learning conseguem classificar registros com e sem falha?
- Como a análise poderia ser ampliada para volumes maiores de dados?

Projeto Disciplina Data Science e Big Data

- Objetivo Geral do projeto

  Desenvolver uma análise de dados industriais para identificar padrões associados à ocorrência de falhas em máquinas da S&M Industry, utilizando técnicas de Data Science, mineração de dados, Machine Learning e processamento de dados com PySpark.

Projeto Disciplina Data Science e Big Data

Objetivos específicos

Explorar e compreender os dados industriais fornecidos.

Identificar e tratar inconsistências, valores ausentes, duplicatas e outliers.

Investigar relações entre variáveis operacionais e ocorrência de falhas.

Projeto Disciplina Data Science e Big Data

Treinar e avaliar modelos de classificação.

Aplicar técnicas de agrupamento para identificar perfis operacionais.

Realizar operações de processamento utilizando Apache Spark.

Elaborar recomendações técnicas fundamentadas nos resultados.

Projeto Disciplina Data Science e Big Data

Etapa 1 — Análise exploratória com Pandas

Importar os dados, verificar tipos de variáveis, calcular estatísticas descritivas e investigar a frequência de falhas por equipamento.

Etapa 2 — Preparação e mineração de dados

Identificar dados ausentes, duplicatas e outliers. Realizar análises estatísticas, correlações e visualizações para descobrir padrões operacionais.

Etapa 3 — Machine Learning supervisionado

Treinar e comparar pelo menos dois algoritmos de classificação, utilizando métricas como acurácia, precisão, recall, F1-score e matriz de confusão.

Projeto Disciplina Data Science e Big Data

Etapa 4 — Machine Learning não supervisionado

Aplicar K-Means para identificar grupos de condições operacionais semelhantes e analisar as características dos agrupamentos.

Etapa 5 — Big Data e tomada de decisão

Utilizar PySpark para processar uma versão ampliada do dataset, realizar transformações e agregações, e apresentar recomendações técnicas fundamentadas nas análises.

Projeto Disciplina Data Science e Big Data

4 - Desenvolvimento do projeto

Etapa 1 — Compreensão e exploração dos dados

Objetivo: compreender a estrutura e as características dos dados operacionais disponibilizados pela S&M Industry Tech.

Projeto Disciplina Data Science e Big Data

4 - Desenvolvimento do projeto

Etapa 1 — Compreensão e exploração dos dados

1. Quantos registros e atributos existem no dataset?
2. Quais são as variáveis disponíveis e quais são seus respectivos tipos?
3. Qual é a distribuição das principais variáveis operacionais?
4. Quantos registros apresentam ocorrência de falhas? Qual é o percentual em relação ao total?
5. Qual equipamento apresenta a maior taxa de falhas?

Projeto Disciplina Data Science e Big Data

4 - Desenvolvimento do projeto

Etapa 2 — Preparação e mineração de dados

Objetivo: identificar problemas de qualidade dos dados e investigar padrões relacionados à ocorrência de falhas.

Projeto Disciplina Data Science e Big Data

4 - Desenvolvimento do projeto

Etapa 2 — Preparação e mineração de dados

1. Existem valores ausentes, registros duplicados ou possíveis outliers?
2. Quais procedimentos foram utilizados para tratar os problemas identificados? Justifique as escolhas.
3. Temperatura e vibração apresentam associação com a frequência de falhas?
4. Existe relação entre horas de operação e ocorrência de falhas?
5. Quais variáveis apresentam maior correlação com a variável falha?
6. A corrente elétrica apresenta associação com a ocorrência de falhas?

Projeto Disciplina Data Science e Big Data

4 - Desenvolvimento do projeto

Etapa 3 — Machine Learning supervisionado

Objetivo: desenvolver e avaliar modelos capazes de classificar os registros operacionais quanto à ocorrência de falhas.

Algoritmos sugeridos: Árvore de Decisão, Random Forest e Regressão Logística.

Projeto Disciplina Data Science e Big Data

4 - Desenvolvimento do projeto

Etapa 3 — Machine Learning supervisionado

Questões investigativas:

1. Quais atributos foram selecionados para o treinamento dos modelos? Justifique.
2. Como os dados foram divididos em conjuntos de treinamento e teste?
3. Qual algoritmo apresentou o melhor desempenho na classificação dos registros?
4. Como interpretar os resultados de acurácia, precisão, recall e F1-score?
5. Quais variáveis apresentaram maior relevância para as previsões dos modelos?
6. Qual é o impacto dos falsos positivos e falsos negativos no contexto da manutenção industrial?

Projeto Disciplina Data Science e Big Data

4 - Desenvolvimento do projeto

Etapa 4 - Machine Learning não supervisionado

Objetivo: identificar agrupamentos de registros operacionais com características semelhantes, utilizando o algoritmo K-Means.

Projeto Disciplina Data Science e Big Data

4 - Desenvolvimento do projeto

Etapa 4 - Machine Learning não supervisionado

Questões investigativas:

1. É possível identificar diferentes perfis operacionais nos dados das máquinas?
2. Quantos agrupamentos foram identificados e como foi definida a quantidade de clusters?
3. Quais características operacionais definem cada agrupamento?
4. Existem clusters que apresentam maior frequência de falhas?
5. Como os agrupamentos identificados poderiam auxiliar no monitoramento das máquinas?

Projeto Disciplina Data Science e Big Data

4 - Desenvolvimento do projeto

Etapa 5 — Big Data e tomada de decisão

Objetivo: utilizar Apache Spark para processar dados industriais e consolidar os resultados do projeto em recomendações para a S&M Industry Tech.

Projeto Disciplina Data Science e Big Data

4 - Desenvolvimento do projeto

Etapa 5 — Big Data e tomada de decisão

1. Como importar, explorar e processar os dados industriais utilizando PySpark?
2. Como realizar operações de filtragem, seleção e agrupamento utilizando Spark?
3. Quais são as principais diferenças entre Pandas e PySpark em relação à manipulação e ao processamento dos dados?
4. Como o processamento distribuído pode contribuir para a análise de grandes volumes de dados industriais?
5. Considerando os resultados das etapas anteriores, quais recomendações técnicas poderiam ser apresentadas à equipe de manutenção da S&M Industry Tech?

Projeto Disciplina Data Science e Big Data

4 - Desenvolvimento do projeto

5. Entregáveis do projeto

Notebook do Google Colab contendo as 5 etapas do projeto com códigos, gráficos e interpretações.

Quais recomendações podem ser apresentadas à equipe de manutenção com base nos resultados obtidos ?

Essas recomendações precisa contemplar as principais descobertas, o modelo de classificação escolhido, suas limitações e possíveis ações para reduzir riscos operacionais.

Projeto Disciplina Data Science e Big Data

Critério de avaliação

Critério	Pontuação
Exploração e compreensão dos dados	15
Preparação e tratamento	15
Análise exploratória e mineração	15
Machine Learning supervisionado	25
Machine Learning não supervisionado	10
Big Data com PySpark	10
Interpretação e recomendações	10
Total	**100**

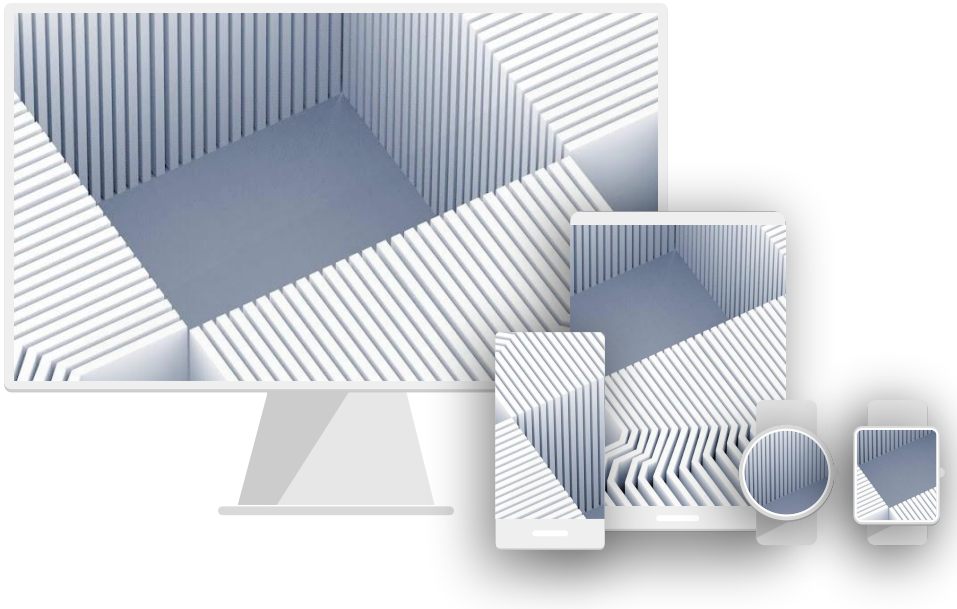
Obrigado !

Prof. Me Daniel Vieira

Email: danielvieira2006@gmail.com

Linkedin: Daniel Vieira

Instagram: Prof daniel.vieira95



UNISENAI
Inovação no
Ensino Superior
para a Indústria